

SAM1 논문 한국어 상세 해설

Segment Anything (Kirillov et al., ICCV 2023)

핵심 개념 · 모델 구조 · SA-1B 데이터 엔진 · Zero-shot 실험 · 한계와 활용 포인트

이 문서는 원문 전체 번역이 아니라, 논문의 구조와 결과를 따라가는 한국어 상세 요약·해설본입니다.

[원문 arXiv 페이지 열기](#)

[원문 PDF 열기](#)

1. 논문 정보

제목	Segment Anything
저자	Alexander Kirillov, Eric Mintun, Nikhila Ravi 외
소속	Meta AI Research (FAIR)
발표	ICCV 2023
arXiv	2304.02643 (2023-04-05 제출)
핵심 기여	Promptable segmentation task + SAM + SA-1B dataset/data engine

한 문장 요약

SAM은 점·박스·마스킹 같은 프롬프트만으로 원하는 대상을 분할하도록 학습된 범용 이미지 분할 모델이며, 이를 가능하게 한 핵심 자산이 1,100만 이미지와 약 11억 개 마스크로 구성된 SA-1B 데이터셋입니다.

2. 핵심 요약

- SAM의 목표는 특정 클래스에 한정된 분할기가 아니라, “무엇을 분할할지”를 프롬프트로 지정하면 다양한 이미지 도메인에서 바로 동작하는 범용 분할 기반 모델을 만드는 것입니다.
- 모델은 3개 구성요소로 나뉩니다: 무거운 이미지 인코더, 가벼운 프롬프트 인코더, 빠른 마스크 디코더. 이미지 임베딩을 한 번 계산한 뒤 여러 프롬프트에 재사용해 상호작용 속도를 높입니다.
- 애매한 한 점 프롬프트가 여러 의미를 가질 수 있으므로, SAM은 한 프롬프트에 대해 여러 후보 마스크와 각 마스크의 품질 점수(예상 IoU)를 함께 출력합니다.
- 데이터 수집은 사람 중심 → 반자동 → 완전 자동의 3단계 데이터 엔진으로 확장되었고, 최종 SA-1B에는 11M 이미지와 1.1B 마스크가 포함됩니다.
- 23개 다양한 데이터셋을 대상으로 한 zero-shot 평가에서 SAM은 한 점 프롬프트 기준 기존 강력한 상호작용 분할기보다 다수 데이터셋에서 우수했고, edge detection·object proposals·instance segmentation·text-to-mask 같은 다른 작업에도 프롬프트 조합으로 전이 가능함을 보였습니다.

3. 문제의식: 왜 “분할용 파운데이션 모델”인가

언어 모델에서는 대규모 사전학습 후 프롬프트만 바꾸어 새로운 작업을 수행하는 방식이 보편화되었습니다. 이 논문은 같은 관점을 이미지 분할에 적용합니다. 즉, 분할도 특정 데이터셋이나 클래스마다 모델을 다시 학습하기보다, 넓은 데이터로 사전학습한 하나의 모델을 프롬프트로 제어할 수 있어야 한다고 봅니다.

- 새로운 데이터셋이나 도메인에서도 zero-shot으로 작동할 수 있는 과제 정의가 필요하다.
- 점, 박스, 마스크 등 서로 다른 프롬프트를 유연하게 받을 수 있는 모델 구조가 필요하다.
- 대규모 분할 데이터가 자연스럽게 존재하지 않으므로, 모델과 데이터 수집을 함께 확장하는 데이터 엔진이 필요하다.

4. Segment Anything Task

4.1 Promptable Segmentation

입력 프롬프트가 무엇이든 그 의도에 맞는 “유효한(valid) 마스크”를 출력하는 것이 핵심 과제입니다. 프롬프트는 전경/배경 점, 박스, 거친 마스크, 자유 형식 텍스트 등일 수 있습니다.

중요한 설계 철학

프롬프트가 애매하더라도 정답 하나를 억지로 평균내는 대신, 가능한 해석 중 적어도 하나에 해당하는 타당한 마스크를 내야 합니다. 이 때문에 다중 마스크 출력이 매우 중요합니다.

4.2 Zero-shot transfer

사전학습 시 사용하지 않았던 downstream task 도 적절한 프롬프트로 바꾸어 해결하는 것이 목표입니다. 예를 들어 외부 객체 검출기가 만든 bounding box 를 SAM 에 넣으면, 별도의 SAM 재학습 없이 instance segmentation 파이프라인을 만들 수 있습니다.

5. SAM 모델 구조

구성요소	역할	논문 핵심
Image Encoder	이미지 전체를 고차원 임베딩으로 변환	MAE 사전학습 ViT 사용. 기본 구현은 ViT-H/16, 입력 1024×1024, 출력 64×64×256 임베딩.
Prompt Encoder	점·박스·마스크·텍스트를 임베딩	점/박스는 위치 인코딩과 프롬프트 타입 임베딩을 결합. 마스크는 convolution 으로 dense embedding.
Mask Decoder	이미지/프롬프트 정보를 결합해 마스크 생성	양방향 cross-attention 을 포함한 경량 Transformer decoder + 동적 마스크 헤드. 여러 후보 마스크와 IoU 점수 출력.

5.1 속도 설계

이미지 인코더는 계산량이 크지만 이미지당 한 번만 수행합니다. 이후 프롬프트를 바꾸어도 이미지 임베딩을 재사용하므로 프롬프트 인코더와 마스크 디코더만 반복 실행됩니다. 논문은 사전 계산된 이미지 임베딩을 사용할 때 브라우저 CPU 환경에서 프롬프트 처리와 마스크 예측이 약 50 ms 수준이라고 보고합니다.

5.2 모호성(ambiguity) 처리

- 단일 점이 "사람 전체", "셔츠", "셔츠의 일부"를 동시에 가리킬 수 있습니다.
- SAM 은 한 프롬프트에서 기본적으로 3 개 후보 마스크를 내도록 설계되었습니다.
- 각 후보에 예상 IoU 를 함께 예측하여 가장 적절한 결과를 고를 수 있게 합니다.
- 학습 시 여러 후보 중 ground truth 와 가장 잘 맞는 마스크에 최소 손실(minimum loss)을 적용합니다.

5.3 학습 손실

마스크 손실은 focal loss 와 dice loss 의 조합을 사용합니다. 학습 중에는 상호작용 분할처럼 여러 라운드의 점/박스/마스크 프롬프트를 시뮬레이션하여 다양한 프롬프트 상황을 학습합니다.

6. 데이터 엔진: 11 억 마스크를 만든 방법

단계	방식	규모	의미
1. Assisted-manual	SAM 이 사람 annotator 의 클릭을 실시간 보조	120k 이미지 / 4.3M 마스크	모델이 좋아질수록 마스크당 평균 주석 시간이 34 초 → 14 초로 감소
2. Semi-automatic	확실한 객체는 자동 생성, 사람은 빠진/어려운 객체 보완	추가 180k 이미지 / 5.9M 마스크	눈에 띄지 않는 객체까지 다양성을 확대
3. Fully automatic	32×32 점 grid, 안정성/loU/NMS/크롭으로 자동 마스크 생성	전체 11M 이미지 / 총 1.1B 마스크	SA-1B 완성, 사람 주석 없이 대규모 확장

6.1 완전 자동 단계의 핵심 필터링

- 각 이미지에 규칙적인 32×32 foreground point grid 를 입력해 후보 마스크를 대량 생성
- 모델의 예상 loU 로 신뢰도가 낮은 마스크 제거
- threshold 를 조금 바꿔도 형태가 유지되는 stable mask 만 유지
- NMS 로 중복 마스크 제거
- 작은 객체를 더 잘 잡기 위해 겹치는 zoom-in crop 도 추가 처리

7. SA-1B 데이터셋

- 약 1,100 만(11M) 장의 라이선스된 고해상도 이미지
- 약 11 억(1.1B) 개의 고품질 분할 마스크
- 공개 이미지에서는 얼굴과 차량 번호판을 블러 처리
- 마스크의 99.1%는 자동 생성
- 전문가가 교정한 샘플과 비교했을 때 자동 마스크의 94%가 loU 90% 이상, 97%가 loU 75% 이상

왜 중요한가

기존 분할 데이터는 대개 클래스와 도메인이 제한되어 있습니다. SA-1B 는 “무엇이든 분할”하는 일반화를 목표로 다양한 크기와 형태의 객체 마스크를 대규모로 제공한다는 점에서 SAM 의 핵심 학습 자원입니다.

8. Responsible AI 분석

논문은 데이터의 지리적·경제적 대표성과 사람 분할의 공정성을 별도 분석합니다. 성별 표현, 연령대, 피부톤 그룹별 사람 분할 성능을 비교했으며, 대부분의 그룹에서 큰 차이를 발견하지 않았다고 보고합니다. 다만 의복 분할에서는 지각된 성별 표현에 따른 편향 징후가 있을 수 있음을 부록에서 언급합니다.

- 모델 자체에서 그룹 간 성능 차이가 작더라도, SAM 이 더 큰 시스템의 구성요소가 될 때 다른 편향이 생길 수 있습니다.
- 실제 서비스에서는 데이터 출처, 프롬프트 방식, downstream detector 등 전체 파이프라인 수준에서 공정성을 점검해야 합니다.

9. Zero-shot 실험 결과

9.1 한 점(Point) → 마스크

23 개 서로 다른 분할 데이터셋에서 single point prompt 를 평가했습니다. SAM 은 강력한 상호작용 분할 기준 모델인 RITM 보다 23 개 중 16 개 데이터셋에서 높은 mIoU 를 보였고, SAM 의 3 개 후보 중 ground truth 와 가장 가까운 마스크를 선택하는 oracle 평가에서는 모든 데이터셋에서 RITM 을 앞섰습니다. 사람 평가에서도 SAM 마스크가 기준 모델보다 일관되게 높은 품질 점수를 받았습니다.

9.2 Object proposals

SAM 자체를 “이미지의 가능한 모든 객체 마스크를 제안하는 도구”처럼 사용할 수 있습니다. LVIS 평가에서 일부 지표는 완전지도 객체 검출기보다 낮지만, 중간/큰 객체 및 rare/common 객체에서는 경쟁력 있는 결과를 보였습니다.

9.3 Instance segmentation

외부 객체 검출기(ViTDet)의 bounding box 를 SAM 에 넣어 zero-shot instance segmentation 을 구성했습니다. COCO 와 LVIS 에서 AP 는 완전지도 ViTDet 에 다소 뒤지지만, 사람 평가에서는 SAM 의 경계가 더 자연스럽고 품질이 더 높게 평가되는 경향이 나타났습니다.

방법	COCO AP	COCO AP_L	LVIS AP	LVIS AP_L
ViTDet-H (fully supervised)	51.0	68.9	46.6	66.3
SAM (zero-shot mask module)	46.5	61.7	44.7	65.5

9.4 Text-to-mask

텍스트 프롬프트를 이용한 분할도 탐색하지만, 논문 자체가 이 부분을 “초기/탐색적 결과”로 규정합니다. 즉, SAM1 의 핵심 강점은 텍스트보다 점·박스·마스크 같은 기하학적 프롬프트에 있습니다.

10. Ablation 에서 읽을 수 있는 것

- 데이터 엔진의 각 단계가 누적될수록 zero-shot 성능이 개선되었습니다.
- 자동 생성 마스크만 사용해도 전체 혼합 데이터 사용 대비 성능 저하가 약 0.5 mIoU 정도로 작아, 자동 데이터의 품질이 충분히 높음을 보여줍니다.
- 전체 11M 이미지 중 1M(약 10%)만 사용해도 전체 데이터와 비슷한 결과가 나오는 구간이 보고되었습니다. 이는 대략 100M 마스크 규모도 강력한 학습 자원이 될 수 있음을 시사합니다.
- ViT-H 는 ViT-B 보다 크게 좋아지지만 ViT-L 대비 이득은 작아, 이미지 인코더 규모를 계속 키우는 것만으로는 효율이 낮아질 수 있습니다.

11. 논문이 직접 인정한 한계

- 가느다란 구조(fine structures)를 놓칠 수 있습니다.
- 작은 분리된 조각을 실제보다 생성하는 현상이 나타날 수 있습니다.
- 계산량이 큰 zoom-in 방식의 전용 분할기만큼 경계가 항상 날카롭지는 않습니다.
- 여러 점을 충분히 제공하는 고정밀 interactive segmentation 에서는 전용 모델이 SAM 보다 우수할 수 있습니다.
- 프롬프트 응답은 빠르지만 무거운 이미지 인코더까지 포함한 전체 처리량은 항상 실시간이라고 보기 어렵습니다.
- Text-to-mask 는 아직 안정적이지 않습니다.
- Semantic segmentation 이나 panoptic segmentation 을 간단한 프롬프트만으로 안정적으로 구현하는 방법은 명확하지 않습니다.
- 특정 전문 도메인에서는 해당 분야에 최적화된 전용 모델이 SAM 보다 우수할 수 있습니다.

12. 실무·교육에서 SAM1 을 이해하는 포인트

"Segment Anything"의 의미	모든 의미론적 클래스를 완벽히 이해한다는 뜻이 아니라, 프롬프트가 지정한 대상을 매우 넓은 범위에서 마스크로 잘라내는 범용 인터페이스에 가깝습니다.
가장 큰 혁신	모델 구조 자체뿐 아니라, 모델이 데이터 생성을 도와 다시 모델을 개선하는 data engine 이 함께 제시된 점입니다.
Foundation model 관점	SAM 을 단독 완성품보다 다른 detector, tracker, 3D, 로봇, 의료/산업 vision 모듈과 조합 가능한 "분할 API"처럼 볼 수 있습니다.
프롬프트 엔지니어링	점, 박스, 이전 마스크, 외부 모델 출력 등을 적절히 설계하면 별도 fine-tuning 없이 새로운 분할 작업으로 확장할 수 있습니다.
현업 적용 주의	고정밀 경계, 작은 구조, 전문 도메인, 대규모 실시간 처리에서는 별도 후처리·fine-tuning·전용 모델 비교가 필요합니다.
SAM2 와의 관계	SAM1 은 정지 이미지 중심의 기본 패러다임을 세웠고, 이후 SAM2 는 이미지뿐 아니라 비디오까지 확장하는 방향으로 발전했습니다.

13. 핵심 용어 정리

Segmentation	이미지의 각 픽셀이 어떤 객체/영역에 속하는지 마스크 형태로 구분하는 작업
Prompt	모델에게 무엇을 분할할지 알려주는 입력. 점, 박스, 마스크, 텍스트 등이 가능
Zero-shot	해당 데이터셋이나 작업으로 추가 학습하지 않고 바로 수행하는 설정
IoU	예측 마스크와 정답 마스크의 겹침 정도를 측정하는 대표 지표
Dice loss	마스크 겹침 비율을 직접 반영하는 분할용 손실
Focal loss	어려운 픽셀/샘플에 더 큰 가중치를 주도록 설계된 손실
NMS	겹치는 후보 중 중복을 제거하는 후처리
ViT	Transformer 를 이미지 패치에 적용한 Vision Transformer
MAE	이미지 패치를 가리고 복원하는 방식의 self-supervised 사전 학습
SA-1B	SAM 개발 과정에서 구축된 11M 이미지 / 1.1B 마스크 데이터셋

14. 원문 및 참고 링크

원문 arXiv: <https://arxiv.org/abs/2304.02643>

원문 PDF: <https://arxiv.org/pdf/2304.02643>

ICCV Open Access: [CVF Segment Anything 페이지](#)

Meta Research: [Meta AI - Segment Anything](#)

공식 프로젝트: <https://segment-anything.com>

15. 발표·시험 대비 8 문장 정리

- SAM1의 핵심 목표는 특정 클래스가 아니라 프롬프트가 가리키는 대상을 범용적으로 분할하는 것입니다.
- 프롬프트는 점, 박스, 마스크가 핵심이며 텍스트 입력은 논문에서 탐색적 기능으로 다뤄집니다.
- 모델은 Image Encoder, Prompt Encoder, Mask Decoder의 3부분으로 나뉩니다.
- 무거운 Image Encoder 결과를 재사용하기 때문에 여러 번 클릭하는 상호작용 분할을 빠르게 처리할 수 있습니다.
- 애매한 점 하나에는 여러 정답이 있을 수 있어 3개의 후보 마스크와 예상 IoU를 출력하는 방식이 중요합니다.
- SA-1B는 모델이 사람의 주석을 돕고, 다시 자동 주석을 확대하는 3단계 data engine으로 만들어졌습니다.
- 논문의 zero-shot 실험은 SAM이 별도 재학습 없이 새로운 데이터와 다른 분할 작업에도 활용될 수 있음을 보여줍니다.
- SAM1의 가치는 최고 정밀도 하나보다 범용성, 조합 가능성, 대규모 데이터 생성 능력에 있습니다.

저작권 안내

이 자료는 원문 논문의 전체 문장 번역본이 아니라 학습·이해를 위한 한국어 요약 및 해설입니다. 정확한 표현, 수식, 표, 부록 세 부사항은 반드시 원문과 함께 확인하세요.