

Segment Anything

SAM 논문 한글 번역본 - 원문 그림·표 포함

Alexander Kirillov 외 · Meta AI Research, FAIR · arXiv:2304.02643v1 (2023-04-05)

Segment Anything

Alexander Kirillov^{1,2,4} Eric Mintun² Nikhila Ravi^{1,2} Hanzi Mao² Chloe Rolland³ Laura Gustafson³
Tete Xiao³ Spencer Whitehead Alexander C. Berg Wan-Yen Lo Piotr Dollár⁴ Ross Girshick⁴
¹project lead ²joint first author ³equal contribution ⁴directional lead
Meta AI Research, FAIR




그림 1. Segment Anything 프로젝트의 세 축: 프롬프트 가능한 분할 과제, Segment Anything Model(SAM), 그리고 SA-1B 구축을 위한 데이터 엔진.

번역 안내

이 문서는 사용자가 업로드한 원문 PDF를 기준으로 작성한 한국어 학술 번역본입니다. 본문(초록, 1-8 장)은 원문의 논리와 실험 결과를 따라 상세히 번역했으며, 기술 부록 A-G 도 구헌 세부사항, 데이터셋·주석·모델 카드, 사람 평가 지침까지 포함해 한국어로 옮겼습니다. 원문에 포함된 Figure 1-20 과 Table 1-9 는 PDF 에서 직접 추출해 관련 번역 문단과 함께 배치했습니다. 참고문헌의 저자명·논문 제목·학술지/학회명은 인용 정확성을 위해 원문 표기를 유지합니다.

초록

우리는 이미지 분할을 위한 새로운 과제, 모델, 데이터셋을 포괄하는 Segment Anything(SA) 프로젝트를 소개한다. 효율적인 모델을 데이터 수집 루프 안에 포함시켜 사용함으로써, 라이선스를 확보하고 개인정보 보호 조치를 적용한 1,100 만 장의 이미지에 대해 10 억 개가 넘는 마스크를 포함하는, 당시까지 가장 큰 규모의 분할 데이터셋을 구축하였다.

모델은 다양한 프롬프트를 입력받을 수 있도록 설계·학습되었으며, 그 결과 새로운 이미지 분포와 새로운 과제로 제로샷 전이가 가능하다. 우리는 여러 과제에서 모델의 능력을 평가했으며, 제로샷 성능이 인상적이고 종종 기존의 완전 지도학습 결과와 경쟁하거나 이를 능가하는 경우도 확인하였다. 컴퓨터 비전의 파운데이션 모델 연구를 촉진하기 위해 Segment Anything Model(SAM)과 1,100 만 장 이미지 및 10 억 개 이상의 마스크를 포함하는 SA-1B 데이터셋을 공개한다.

1. 서론

웹 규모 데이터셋으로 사전학습된 대규모 언어 모델은 강력한 제로샷(zero-shot) 및 퓨샷(few-shot) 일반화 성능을 보이며 자연어처리 분야를 변화시키고 있다 [10]. 이러한 "파운데이션 모델" [8]은 학습 중 보지 못한 과제와 데이터 분포에도 일반화할 수 있다. 이 능력은 흔히 프롬프트 엔지니어링을 통해 구현된다. 사람이 작성한 텍스트 프롬프트를 모델에 입력하여 주어진 과제에 적절한 텍스트 응답을 생성하게 하는 방식이다. 웹의 방대한 텍스트 말뭉치로 모델 규모, 데이터 규모, 총 학습 연산량을 키우면 제로샷·퓨샷 성능이 미세조정된 모델과 놀라울 정도로 비슷해지며, 경우에 따라서는 동일한 수준에 이르기도 한다 [10, 21, 56, 51].

컴퓨터 비전에서도 파운데이션 모델이 연구되어 왔지만 자연어처리만큼 폭넓지는 않았다. 대표적인 예는 웹에서 수집한 텍스트-이미지 쌍을 정렬하는 접근이다. CLIP [82]과 ALIGN [55]은 대조학습으로 텍스트 인코더와 이미지 인코더를 학습하여 두 모달리티를 정렬한다. 학습이 끝나면 설계된 텍스트 프롬프트를 이용해 새로운 시각 개념과 데이터 분포에 제로샷으로 일반화할 수 있다. 이러한 인코더는 다른 모듈과 결합되어 이미지 생성 같은 다운스트림 과제를 수행하는 데도 유용하다. 다만 컴퓨터 비전에는 비전-언어 정렬만으로는 포괄되지 않는 매우 다양한 문제가 있으며, 많은 문제에는 대규모 학습 데이터가 존재하지 않는다.

이 연구의 목표는 이미지 분할을 위한 파운데이션 모델을 구축하는 것이다. 즉, 프롬프트를 받을 수 있는 모델을 설계하고 강력한 일반화를 가능하게 하는 과제로 광범위한 데이터셋에서 사전학습한 뒤, 프롬프트 엔지니어링만으로 새로운 데이터 분포의 다양한 분할 문제를 해결하고자 한다.

이 계획의 성공은 세 가지 요소, 즉 과제(task), 모델(model), 데이터(data)에 달려 있다. 이를 위해 다음 세 질문을 다룬다.

- 어떤 과제가 제로샷 일반화를 가능하게 하는가?
- 그 과제에 적합한 모델 구조는 무엇인가?
- 그 과제와 모델을 충분히 학습시킬 데이터는 어떻게 확보할 수 있는가?

이 세 질문은 서로 얽혀 있으므로 종합적인 해법이 필요하다. 우리는 먼저 강력한 사전학습 목표가 되면서 동시에 다양한 다운스트림 응용을 지원할 만큼 일반적인 '프롬프트 가능한 분할(promptable segmentation)' 과제를 정의한다. 이 과제를 실제 상호작용에 활용하려면 모델이 다양한 프롬프트를 지원하고, 프롬프트가 주어졌을 때 분할 마스크를 실시간에 가깝게 출력해야 한다. 또한 모델을 학습하려면 규모가 크고 다양한 데이터가 필요하다. 그러나 인터넷에는 웹 규모의 분할 마스크 데이터가 자연스럽게 존재하지 않는다. 따라서 우리는 효율적인 모델로 데이터 수

집을 보조하고, 새로 수집한 데이터로 다시 모델을 개선하는 과정을 반복하는 '데이터 엔진(data engine)'을 구축한다.

Segment Anything

Alexander Kirillov^{1,2,4} Eric Mintun² Nikhila Ravi^{1,2} Hanzi Mao² Chloe Rolland³ Laura Gustafson³
Tete Xiao³ Spencer Whitehead Alexander C. Berg Wan-Yen Lo Piotr Dollár⁴ Ross Girshick⁴
¹project lead ²joint first author ³equal contribution ⁴directional lead
Meta AI Research, FAIR




그림 1. 분할용 파운데이션 모델을 만들기 위해 서로 연결된 세 요소를 제안한다. (a) 프롬프트 가능한 분할 과제, (b) 데이터 주석을 지원하고 프롬프트 엔지니어링으로 여러 과제에 제로샷 전이를 가능하게 하는 SAM, (c) 10억 개가 넘는 마스크의 SA-1B를 수집하는 데이터 엔진.

과제 (§ 2)

NLP와 최근 컴퓨터 비전에서 파운데이션 모델은 프롬프트 기법을 사용해 새로운 데이터셋과 과제에 제로샷·퓨샷 학습을 수행하는 유망한 방향으로 자리잡고 있다. 이에 착안해 우리는 임의의 분할 프롬프트가 주어졌을 때 유효한 분할 마스크를 반환하는 '프롬프트 가능한 분할' 과제를 제안한다. 프롬프트는 이미지에서 무엇을 분할해야 하는지를 나타내는 정보이며, 객체를 가리키는 공간 정보나 텍스트 정보 등을 포함할 수 있다. '유효한 마스크'라는 요구는 프롬프트가 모호해 여러 객체를 의미할 수 있을 때에도 그중 적어도 하나에 대해 합리적인 마스크를 출력해야 한다는 뜻이다. 예를 들어 셔츠 위의 한 점은 셔츠 자체 또는 셔츠를 입은 사람을 가리킬 수 있다.

모델 (§ 3)

프롬프트 가능한 분할 과제와 실제 사용 목표는 모델 구조에 세 가지 제약을 준다. 다양한 프롬프트를 지원해야 하고, 상호작용을 위해 마스크를 상각된(amortized) 실시간 속도로 계산해야 하며, 모호성을 다룰 수 있어야 한다. 놀랍게도 비교적 단순한 설계로 이 요구를 만족할 수 있다. 강력한 이미지 인코더가 이미지 임베딩을 만들고, 프롬프트 인코더가 프롬프트를 임베딩하며, 두 정보를 경량 마스크 디코더가 결합하여 분할 마스크를 예측한다. 이를 Segment Anything Model, 즉 SAM이라 부른다. 이미지 인코더와 빠른 프롬프트 인코더/마스크 디코더를 분리하면 동일한 이미지 임베딩을 여러 프롬프트에 재사용할 수 있다. 미리 계산된 이미지 임베딩이 있으면 프롬프트 인코더와 마스크 디코더는 웹 브라우저에서 약 50ms에 마스크를 예측한다. 점, 박스, 마스크 프롬프트를 중심으로 다루며 자유 형식 텍스트 프롬프트에 대한 초기 결과도 제시한다. 모호성을 다루기 위해 하나의 프롬프트에 대해 여러 마스크를 예측하도록 설계한다.

데이터 엔진(§ 4)

새로운 데이터 분포에 강하게 일반화하려면 기존 분할 데이터셋보다 훨씬 크고 다양한 마스크 집합으로 SAM 을 학습해야 한다. 마스크는 인터넷에 자연스럽게 풍부하게 존재하지 않으므로, 모델과 데이터 주석 과정을 함께 발전시키는 model-in-the-loop 방식의 데이터 엔진을 구축하였다. 데이터 엔진은 세 단계로 구성된다. 첫째는 SAM 이 주석자를 보조하는 모델 보조 수동 단계, 둘째는 일부 객체를 SAM 이 자동 생성하고 주석자가 나머지 객체를 추가하는 반자동 단계, 셋째는 규칙적인 전경 점 격자로 SAM 을 프롬프트하여 이미지당 평균 약 100 개의 고품질 마스크를 생성하는 완전 자동 단계이다.

데이터셋(§ 5)

최종 데이터셋 SA-1B 는 라이선스를 확보하고 개인정보를 보호한 1,100 만 장의 이미지에서 10 억 개가 넘는 마스크를 포함한다. 최종 데이터 엔진 단계로 완전히 자동 수집했으며, 기존 어떤 분할 데이터셋보다도 훨씬 많은 마스크를 보유한다. 저자들은 자동 마스크가 높은 품질과 다양성을 갖는지 여러 방식으로 검증한다.

책임 있는 AI(§ 6)

SA-1B 와 SAM 을 사용할 때 발생할 수 있는 공정성 문제와 편향을 조사한다. SA-1B 는 지리적·경제적으로 다양한 국가의 이미지를 포함하며, 사람 분할 성능이 여러 집단에서 대체로 유사함을 보고한다. 다만 후속 분석에서 특정 조건의 의복 분할에는 편향 징후도 관찰된다.

실험(§ 7)

23 개의 다양한 분할 데이터셋으로 광범위한 평가를 수행한다. 단일 전경 점만으로도 높은 품질의 마스크를 생성하며, 프롬프트 엔지니어링을 통해 엣지 검출, 객체 제안 생성, 인스턴스 분할, 텍스트-투-마스크 등 학습 과제와 다른 다운스트림 과제에서도 제로샷 전이를 보인다.

공개

SA-1B 는 연구 목적으로 공개되며, SAM 은 허용적인 Apache 2.0 라이선스로 제공된다. 온라인 데모도 함께 제공된다.




그림 2. 새로 제안한 SA-1B 데이터셋의 예시. 다양한 고해상도 이미지 위에 SAM 이 완전 자동으로 생성한 분할 마스크를 겹쳐 보여준다. SA-1B 는 1,100 만 장의 이미지와 약 11 억 개의 고품질 마스크를 포함하며, 이미지당 평균 약 100 개의 마스크가 존재한다.

2. Segment Anything 과제

우리는 NLP 에서 다음 토큰 예측(next-token prediction)이 파운데이션 모델의 사전학습 과제로 사용되고, 프롬프트 엔지니어링을 통해 다양한 다운스트림 과제를 해결하는 데 활용된다는 점에서 영감을 얻었다 [10]. 이미지 분할에서도 유사한 역할을 할 수 있는 과제를 정의하고자 한다.

과제

NLP의 프롬프트 개념을 분할 문제로 옮기면, 프롬프트는 전경/배경 점의 집합, 대략적인 박스나 마스크, 자유 형식 텍스트, 또는 이미지에서 무엇을 분할해야 하는지를 나타내는 일반적인 정보가 될 수 있다. 프롬프트 가능한 분할 과제는 임의의 프롬프트가 주어졌을 때 '유효한(valid)' 분할 마스크를 반환하는 것이다.

여기서 유효하다는 것은 프롬프트가 모호하여 여러 객체를 가리킬 수 있더라도 그중 적어도 하나에 대해 합리적인 마스크를 출력해야 한다는 의미이다. 예를 들어 셔츠 위의 한 점은 셔츠 또는 사람을 의미할 수 있다. 이는 모호한 프롬프트가 주어졌을 때 언어 모델이 의미가 통하는 답변을 내놓기를 기대하는 것과 유사하다. 이 과제를 선택한 이유는 자연스러운 사전학습 알고리즘을 만들 수 있고, 프롬프트를 통해 다운스트림 분할 과제로 제로샷 전이하는 일반적인 방법을 제공하기 때문이다.



그림 3. 각 열은 하나의 모호한 점 프롬프트(초록색 원)에서 SAM이 생성한 서로 다른 세 개의 유효한 마스크를 보여준다. 하나의 점이 전체 객체, 부분, 하위 부분을 동시에 의미할 수 있음을 보여주는 예다.

사전학습

각 학습 샘플에 대해 점, 박스, 마스크 등의 프롬프트 시퀀스를 모의 생성하고, 모델의 마스크 예측을 정답 마스크와 비교한다. 이 방식은 인터랙티브 분할 [109, 70]에서 가져왔지만 목적은 다르다. 기존 인터랙티브 분할은 충분한 사용자 입력 뒤에 유효한 마스크를 얻는 것을 목표로 하는 반면, SAM의 목표는 프롬프트가 모호한 경우에도 어떤 프롬프트에서도 항상 유효한 마스크를 예측하는 것이다. 이 성질은 데이터 엔진의 자동 주석처럼 모호성이 있는 실제 사용 사례에서 특히 중요하다.

제로샷 전이

사전학습을 통해 모델은 추론 시 다양한 프롬프트에 적절히 반응하는 능력을 갖게 된다. 따라서 적절한 프롬프트를 설계하면 다운스트림 과제를 해결할 수 있다. 예를 들어 고양이의 바운딩 박스를 찾아주는 검출기가 있다면, 그 박스를 SAM의 프롬프트로 넣어 고양이 인스턴스 분할을 수행할 수 있다. 자동 데이터 라벨링 외에도 § 7에서 서로 다른 다섯 가지 예시 과제를 평가한다.

관련 과제

분할 분야에는 인터랙티브 분할, 엣지 검출, 슈퍼픽셀화, 객체 제안 생성, 전경 분할, 시맨틱 분할, 인스턴스 분할, 파노믹 분할 등 다양한 문제가 있다. 프롬프트 가능한 분할의 목표는 이들 모든 과제를 하나의 고정된 멀티태스크 모델로 직접 수행하는 것이 아니라, 프롬프트 엔지니어링과 시스템 조합을 통해 기존 또는 새로운 여러 과제에 적응할 수 있는 폭넓은 모델을 만드는 것이다. 이는 학습 시 정해진 과제 집합과 테스트 과제 집합이 동일한 전통적 멀티태스크 분할과 구별된다.

논의

프롬프팅과 모델 조합(composition)은 단일 모델을 확장 가능한 방식으로 사용하는 강력한 도구이며, 모델 설계 당시 예상하지 못한 과제를 수행하게 할 수도 있다. 예를 들어 CLIP은 DALL·E와 같은 더 큰 이미지 생성 시스템에서 텍스트-이미지 정렬 구성요소로 쓰인다. SAM 역시 사람과 상호작용하는 도구일 뿐 아니라 더 큰 알고리즘 시스템의 한 구성요소로 조합될 수 있도록 설계되었다.

3. Segment Anything Model

이 절에서는 프롬프트 가능한 분할을 위한 Segment Anything Model(SAM)을 설명한다. 그림 4와 같이 SAM은 이미지 인코더, 유연한 프롬프트 인코더, 빠른 마스크 디코더의 세 부분으로 구성된다. Transformer 기반 비전 모델 [14, 33, 20, 62]을 토대로 하되 상각된 실시간 성능을 위한 절충을 적용한다.




그림 4. SAM 개요. 계산량이 큰 이미지 인코더가 한 번 이미지 임베딩을 만든 뒤, 다양한 입력 프롬프트를 빠르게 질의하여 객체 마스크를 생성한다. 모호한 프롬프트의 경우 여러 개의 유효한 마스크와 각 마스크의 신뢰도 점수를 출력할 수 있다.

이미지 인코더

확장성과 강력한 사전학습 기법의 장점을 활용하기 위해 MAE [47]로 사전학습된 Vision Transformer(ViT) [33]를 사용하고, 고해상도 입력을 처리하도록 최소한으로 수정한다 [62]. 이미지 인코더는 이미지마다 한 번만 실행되며, 사용자가 프롬프트를 주기 전에 미리 계산할 수 있다.

프롬프트 인코더

프롬프트는 희소(sparse) 프롬프트와 밀집(dense) 프롬프트로 구분한다. 희소 프롬프트에는 점, 박스, 텍스트가 포함된다. 점과 박스는 위치 인코딩에 각 프롬프트 유형에 대한 학습 임베딩을 더해 표현하고, 자유 형식 텍스트는 CLIP [82]의 텍스트 인코더를 사용한다. 밀집 프롬프트인 마스크는 합성곱으로 임베딩한 뒤 이미지 임베딩에 원소 별로 더한다.

마스크 디코더

마스크 디코더는 이미지 임베딩, 프롬프트 임베딩, 출력 토큰을 효율적으로 결합해 마스크를 예측한다. Transformer 디코더 블록 [103]을 수정한 구조와 동적 마스크 예측 헤드를 사용한다. 프롬프트 자기어텐션과 양방향 교차어텐션, 즉 프롬프트→이미지와 이미지→프롬프트 방향을 모두 사용해 임베딩을 업데이트한다. 두 개의 블록을 통과한 후 이미지 임베딩을 업샘플링하고, MLP가 출력 토큰을 동적 선형 분류기로 매핑하여 각 이미지 위치의 전경 확률을 계산한다.

모호성 해결

모호한 프롬프트에 하나의 출력만 사용하면 모델은 여러 유효한 마스크를 평균하려는 경향이 생긴다. 이를 해결하기 위해 하나의 프롬프트에서 여러 출력 마스크를 예측한다. 저자들은 일반적인 중첩 관계가 전체(whole)-부분(part)-하위부분(subpart)의 세 단계인 경우가 많아 세 개의 마스크 출력이면 충분하다고 보았다. 학습 시 각 예측 마스크와 정답의 손실을 계산하고 가장 작은 손실만 역전파한다. 또한 각 마스크의 예상 IoU를 신뢰도 점수로 예측하여 결과를 순위화한다.

효율성

전체 설계의 중요한 목표는 효율성이다. 이미지 임베딩을 미리 계산해 두면 프롬프트 인코더와 마스크 디코더는 CPU 기반 웹 브라우저에서 약 50ms에 실행된다. 따라서 사용자가 프롬프트를 연속으로 수정하는 실시간 상호작용이 가능하다.

손실과 학습

마스크 예측은 focal loss [65]와 dice loss [73]의 선형 결합으로 지도한다. 텍스트 프롬프트 실험을 제외하면 주로 기하학적 프롬프트를 혼합해 학습한다. 인터랙티브 분할 상황을 모의하기 위해 마스크당 11번의 라운드에서 프롬프트를 무작위로 샘플링하고, 이를 통해 데이터 엔진과 자연스럽게 통합되도록 한다.

4. Segment Anything 데이터 엔진

인터넷에는 분할 마스크가 풍부하게 존재하지 않기 때문에, 11억 개의 마스크를 가진 SA-1B를 구축하기 위해 데이터 엔진을 설계했다. 데이터 엔진은 (1) 모델 보조 수동 주석, (2) 자동 예측과 모델 보조 주석을 혼합한 반자동, (3) 주석자의 개입 없이 모델이 마스크를 생성하는 완전 자동의 세 단계로 진행된다.

4.1 모델 보조 수동 단계

전통적인 인터랙티브 분할과 유사하게 전문 주석자들이 SAM 기반 웹 도구에서 전경/배경 객체 점을 클릭하여 마스크를 라벨링했다. 필요한 경우 픽셀 단위 브러시와 지우개로 마스크를 수정할 수 있었다. 미리 계산된 이미지 임베딩을 사용하기 때문에 모델 보조 주석은 브라우저에서 실시간으로 동작했다.

객체 라벨링에 의미론적 범주 제한을 두지 않았으며, 주석자는 이름을 붙일 수 있는 개별 물체(things)뿐 아니라 재질·영역처럼 경계가 있는 비정형 영역(stuff)도 자유롭게 라벨링했다. 이름이나 설명 자체는 수집하지 않았다. 주석자는 눈에 띄는 객체부터 순서대로 라벨링하고, 하나의 마스크에 30 초 이상 걸리면 다음 이미지로 넘어가도록 권장 받았다.

이 단계 초기에는 공개 분할 데이터셋으로 SAM 을 학습했다. 충분한 새 주석이 모인 후부터는 새로 수집한 마스크만으로 재학습했다. 데이터가 늘어나면서 이미지 인코더를 ViT-B 에서 ViT-H 까지 확장했고 구조도 일부 수정했으며, 전체적으로 모델을 6 번 재학습했다. 모델이 개선됨에 따라 마스크 하나당 평균 주석 시간은 34 초에서 14 초로 감소했다. 14 초는 COCO 의 마스크 주석보다 약 6.5 배 빠르고, 극점 기반 바운딩 박스 라벨링보다 약 2 배 느린 수준이다. 이미지당 평균 마스크 수는 20 개에서 44 개로 증가했다. 이 단계에서 12 만 장의 이미지로부터 430 만 개의 마스크를 수집했다.

4.2 반자동 단계

이 단계의 목표는 덜 눈에 띄는 객체까지 포함해 마스크의 다양성을 높이는 것이다. 먼저 모델이 신뢰도가 높은 마스크를 자동 검출하고, 주석자에게 그 마스크가 미리 채워진 이미지를 보여준 뒤 아직 주석되지 않은 객체를 추가하도록 했다. 신뢰도 높은 마스크를 찾기 위해 첫 단계의 모든 마스크를 하나의 일반적인 'object' 범주로 간주하여 바운딩 박스 검출기 [84]를 학습했다.

이 단계에서 18 만 장의 이미지에 590 만 개의 마스크를 추가로 수집하여 누적 1,020 만 개가 되었다. 새 데이터로 모델을 5 차례 재학습했다. 자동 마스크를 제외한 수동 주석 시간은 평균 34 초로 다시 증가했는데, 남은 객체들이 더 어렵기 때문이다. 자동 마스크를 포함한 이미지당 평균 마스크 수는 44 개에서 72 개로 증가했다.

4.3 완전 자동 단계

마지막 단계에서는 주석이 완전히 자동화되었다. 이것이 가능했던 이유는 두 가지다. 첫째, 이전 두 단계에서 충분하고 다양한 마스크를 확보하여 모델이 크게 개선되었다. 둘째, 모호성을 인식하는 모델을 완성하여 한 점이 여러 가능한 객체를 나타내는 경우에도 유효한 마스크 후보를 만들 수 있게 되었다.

구체적으로 각 이미지에 32×32 규칙 격자의 점을 프롬프트로 입력하고, 각 점에서 유효한 객체에 대응할 수 있는 여러 마스크를 예측했다. 점이 객체의 부분이나 하위부분에 놓인 경우 모델은 하위부분, 부분, 전체 객체를 함께 반환할 수 있다. 예측 IoU 모듈로 신뢰도가 높은 마스크를 고르고, 확률 맵을 $0.5-\delta$ 와 $0.5+\delta$ 에서 임계값 처리했을 때 결과가 유사한 '안정적인(stable)' 마스크만 선택했다. 이후 NMS 로 중복을 제거했다. 작은 객체의 품질을 높이기 위해 겹치는 확대 크롭에서도 마스크를 생성했다. 이 방식을 1,100 만 장 전체 이미지에 적용하여 총 11 억 개의 고품질 마스크를 생성했다.

5. Segment Anything 데이터셋

SA-1B 는 다양하고 고해상도이며 라이선스를 확보하고 개인정보 보호 조치를 적용한 1,100 만 장의 이미지와 데이터 엔진으로 수집한 11 억 개의 고품질 분할 마스크로 이루어진다. 기존 데이터셋과 비교하고 마스크 품질 및 속성을 분석하며, 향후 컴퓨터 비전 파운데이션 모델 연구를 위해 공개한다.

이미지

사진작가와 직접 협업하는 공급자로부터 새로운 1,100 만 장의 이미지 집합을 라이선스했다. 평균 해상도는 약 3300×4950 픽셀로 매우 높아 저장과 접근성 측면에서 부담이 있으므로, 공개 버전은 짧은 변의 길이를 1500 픽셀

로 다운샘플링한다. 그래도 COCO 의 약 480×640 해상도보다 훨씬 크다. 공개 이미지에서는 얼굴과 차량 번호판을 블러 처리한다.

마스크

데이터 엔진은 총 11 억 개의 마스크를 만들었으며 이 중 99.1%가 완전 자동 생성이다. 따라서 자동 마스크의 품질이 핵심이다. 저자들은 전문 주석과 직접 비교하고, 여러 대표 분할 데이터셋과 마스크 속성을 비교한다. 아래 분석과 § 7 의 실험을 통해 자동 마스크가 높은 품질을 갖고 모델 학습에 효과적이라고 결론짓는다. 이러한 결과를 바탕으로 공개되는 SA-1B 에는 자동 생성 마스크만 포함한다.

마스크 품질

무작위로 500 장, 약 5 만 개 마스크를 뽑아 전문 주석자에게 모든 마스크를 수정하도록 했다. SAM 과 픽셀 정밀 브러시/지우개를 사용해 자동 예측 마스크를 전문적으로 교정했고, 자동 마스크와 교정 마스크 쌍의 IoU 를 계산했다. 그 결과 94%가 IoU 90%를 넘었고, 97%가 75%를 넘었다. 기존 연구가 보고한 주석자 간 일치도가 85-91% IoU 수준이라는 점을 고려하면 자동 마스크의 품질이 높음을 시사한다. § 7 의 사람 평가에서도 자동 마스크 품질이 여러 데이터셋에 비해 높고, 자동 마스크만으로 학습한 모델이 데이터 엔진의 모든 마스크를 사용한 모델과 거의 비슷한 성능을 보인다.




그림 5. 이미지 크기로 정규화한 마스크 중심 위치 분포. SA-1B 와 기존 대형 분할 데이터셋의 객체 중심 위치 편향을 비교한다.




그림 6. 데이터셋의 마스크 속성 비교. SA-1B 는 기존 대형 데이터셋보다 이미지 수와 마스크 수가 압도적으로 크고, 이미지당 마스크 수가 많으며 작은·중간 크기 객체를 더 많이 포함한다. 마스크의 오목성(concavity) 분포는 다른 데이터셋과 대체로 유사하다.

has 11 × more images and 400 × more masks than the largest existing segmentation dataset Open Images [60].




그림 7. SA-1B 이미지의 추정 지리적 분포. 대부분의 국가가 1,000 장 이상의 이미지를 가지며, 이미지 수가 가장 많은 세 국가는 서로 다른 지역에 위치한다.

마스크 속성

객체 중심의 공간 분포를 비교하면 모든 데이터셋에서 사진 촬영의 중앙 편향이 존재하지만, SA-1B는 LVIS v1 및 ADE20K 보다 이미지 모서리까지 더 넓게 포함한다. COCO 와 Open Images 는 중앙 편향이 더 강하다. 규모 측면에서 SA-1B 는 두 번째로 큰 Open Images 보다 이미지 수가 약 11 배, 마스크 수가 약 400 배 많고, 이미지당 평균 마스크 수는 약 36 배 많다. ADE20K 도 이미지당 마스크 수가 SA-1B 보다 약 3.5 배 적다.

이미지 대비 마스크 상대 크기를 보면 SA-1B 는 이미지당 마스크가 많기 때문에 작은·중간 상대 크기의 마스크 비율이 더 높다. 형상 복잡도를 마스크 오목성(1 - 마스크 면적/볼록 껍질 면적)으로 비교하면 크기 분포를 통제한 뒤에도 다른 데이터셋과 전반적으로 유사한 분포를 보인다.

	# countries	SA-1B		% images		
		#imgs	#masks	SA-1B	COCO	O.I.
Africa	54	300k	28M	2.8%	3.0%	1.7%
Asia & Oceania	70	3.9M	423M	36.2%	11.4%	14.3%
Europe	47	5.4M	540M	49.8%	34.2%	36.2%
Latin America & Carib.	42	380k	36M	3.5%	3.1%	5.0%
North America	4	830k	80M	7.7%	48.3%	42.8%
high income countries	81	5.8M	598M	54.0%	89.1%	87.5%
middle income countries	108	4.9M	499M	45.0%	10.5%	12.0%
low income countries	28	100k	9.4M	0.9%	0.4%	0.5%

표 1. SA-1B, COCO, Open Images 의 지역 및 소득 수준별 표현 비교. SA-1B 는 유럽, 아시아·오세아니아, 중간소득 국가 비중이 더 높지만, 모든 데이터셋에서 아프리카와 저소득 국가가 과소대표된다.

6. Segment Anything 책임 있는 AI(RAI) 분석

저자들은 SA-1B 와 SAM 을 사용할 때 발생할 수 있는 공정성 우려와 편향을 조사한다. 특히 SA-1B 의 지리적·소득 수준 분포와 사람의 보호 속성별 SAM 성능을 분석하며, 부록에는 데이터셋·주석·모델 카드를 제공한다.

지리적·소득 수준 표현

이미지의 촬영 국가를 추정하여 SA-1B, COCO, Open Images 를 비교한다. SA-1B 는 유럽 및 아시아·오세아니아 이미지 비율이 상대적으로 높고 중간소득 국가 비중도 더 높다. 그러나 세 데이터셋 모두 아프리카와 저소득 국가를 과소대표한다. 그럼에도 SA-1B 에서는 아프리카를 포함한 모든 지역에 최소 2,800 만 개의 마스크가 존재하며, 이는 이전 어떤 단일 데이터셋의 전체 마스크 수보다도 약 10 배 많은 규모이다. 지역과 소득 수준에 따른 이미지당 마스크 수는 대체로 94-108 개 범위로 유사하다.

	mIoU at			mIoU at	
	1 point	3 points		1 point	3 points
<i>perceived gender presentation</i>			<i>perceived skin tone</i>		
feminine	54.4 ± 1.7	90.4 ± 0.6	1	52.9 ± 2.2	91.0 ± 0.9
masculine	55.7 ± 1.7	90.1 ± 0.6	2	51.5 ± 1.4	91.1 ± 0.5
<i>perceived age group</i>			3	52.2 ± 1.9	91.4 ± 0.7
older	62.9 ± 6.7	92.6 ± 1.3	4	51.5 ± 2.7	91.7 ± 1.0
middle	54.5 ± 1.3	90.2 ± 0.5	5	52.4 ± 4.2	92.5 ± 1.4
young	54.2 ± 2.2	91.2 ± 0.7	6	56.7 ± 6.3	91.2 ± 2.4

표 2. 사람 분할에서 지각된 성별 표현, 연령대, 피부톤에 따른 SAM 성능(mIoU). 95% 신뢰구간을 제시하며, 대부분의 집단 간 신뢰구간이 겹친다.

사람 분할의 공정성

지각된 성별 표현, 지각된 연령대, 지각된 피부톤에 따른 SAM의 성능 차이를 측정한다. 성별 표현과 연령은 MIAP [87], 피부톤은 별도 데이터셋을 사용하며 1 점 및 3 점 무작위 프롬프트 기반의 모의 인터랙티브 분할을 평가한다.

성별 표현에서는 여성 표현이 기존 검출·분할 데이터셋에서 과소대표된다는 선행 연구가 있지만 SAM은 두 집단에서 대체로 유사한 성능을 보였다. 연령대에서는 고령으로 지각되는 집단에서 평균 성능이 가장 높지만 신뢰구간이 크다. 피부톤은 Fitzpatrick 1(가장 밝음)-6(가장 어두움) 척도로 비교했을 때 평균값에 일부 차이가 있으나 통계적으로 뚜렷한 집단 차이를 발견하지 못했다. 다만 SAM이 더 큰 시스템의 구성요소로 사용될 때 편향이 새롭게 나타날 수 있음을 저자들은 명시한다. 부록의 의복 분할 분석에서는 지각된 성별 표현에 따른 편향의 징후가 관찰된다.

7. 제로샷 전이 실험

이 절에서는 SAM의 제로샷 전이 능력을 평가한다. 다섯 개 과제를 다루며, 그중 네 개는 SAM이 학습한 '프롬프트 가능한 분할' 과제와 상당히 다르다. 학습 중 보지 못한 데이터셋과 과제에서 평가하며, 여기서 제로샷 전이라는 용어는 CLIP [82]에서의 사용 방식과 같다. 수중 이미지나 1인칭(egocentric) 이미지처럼 SA-1B에 포함되지 않았다고 판단되는 새로운 분포도 포함한다.

첫 실험은 임의의 프롬프트에서 유효한 마스크를 생성한다는 핵심 목표를 검증한다. 특히 하나의 전경 점은 다른 프롬프트보다 모호하기 때문에 어려운 조건으로 강조한다. 이어서 저수준에서 고수준으로 이어지는 네 과제를 프롬프트 엔지니어링으로 해결한다. (1) 엣지 검출, (2) 모든 객체를 분할하는 객체 제안 생성, (3) 검출된 객체를 분할하는 인스턴스 분할, (4) 자유 형식 텍스트로 객체를 분할하는 개념증명 실험이다. 마지막에는 절제(ablation) 연구를 수행한다.

별도 언급이 없으면 SAM은 MAE 사전학습 ViT-H 이미지 인코더를 사용하고, 데이터 엔진의 최종 단계에서 자동 생성된 마스크만 포함하는 SA-1B로 학습한다.

7.1 단일 점 프롬프트의 제로샷 유효 마스크 평가

과제

하나의 전경 점에서 객체를 분할한다. 한 점은 여러 객체를 가리킬 수 있어 본질적으로 불확정적인 문제다. 대부분의 데이터셋 정답 마스크는 가능한 모든 해를 열거하지 않으므로 자동 지표만으로는 공정한 평가가 어려울 수 있다. 따라서 표준 mIoU 와 함께 사람이 마스크 품질을 1 점(무의미)부터 10 점(픽셀 수준으로 완벽)까지 평가하는 실험을 수행한다.

기본적으로 정답 마스크 내부 거리 변환이 최대가 되는 '중심'에서 점을 샘플링한다. SAM 은 여러 마스크를 예측할 수 있지만 기본 자동 평가는 가장 높은 신뢰도의 마스크 하나를 사용한다. 주요 비교 모델은 강력한 인터랙티브 분할 기 RITM [92]이며, 추가로 SimpleClick 과 FocalClick 도 비교한다.

데이터셋

서로 다른 이미지 분포를 갖는 23 개 분할 데이터셋으로 새 평가 모음을 구성한다. 현미경, X-ray, 수중, 드론, 시뮬레이션, 자율주행, 1 인칭, 회화 등 매우 다양한 도메인을 포함한다.




그림 8. SAM 의 제로샷 전이 능력 평가에 사용한 23 개 분할 데이터셋의 예시.




그림 9. 23 개 데이터셋의 점→마스크 평가. (a) SAM 과 RITM 의 단일 중심점 mIoU 차이, 원 표시는 SAM 의 세 출력 중 정답과 가장 잘 맞는 oracle 결과. (b) 사람 평가의 마스크 품질. (c,d) 점 수를 늘렸을 때 중심점/무작위점 조건의 mIoU.

결과

23 개 전체 데이터셋의 자동 mIoU 평가에서 SAM 은 23 개 중 16 개에서 RITM 보다 높은 결과를 보였고, 일부 데이터셋에서는 약 47 IoU 포인트까지 차이가 났다. SAM 의 세 마스크 중 정답에 가장 가까운 마스크를 선택하는

oracle 평가에서는 모든 데이터셋에서 RITM 을 능가했다. 이는 단일 점의 모호성이 자동 평가에 상당한 영향을 준다는 사실을 보여준다.

사람 평가에서는 주석자들이 SAM 의 마스크 품질을 RITM 보다 일관되게 높게 평가했다. 모호성을 인식하지 않는 단일 출력 버전의 SAM 은 완전한 SAM 보다 낮았지만 RITM 보다는 높았다. SAM 의 평균 평점은 7-9 점 사이로, 객체를 식별할 수 있고 오류가 작고 드물다는 수준에 해당한다. DRAM 이나 IBD 처럼 자동 지표에서는 SAM 이 뒤지는 데이터셋에서도 사람 평가는 SAM 을 더 높게 평가했다.

점 수가 1 개에서 9 개로 늘어나면 과제가 쉬워지면서 모델 간 차이는 줄어든다. SAM 은 매우 높은 IoU 영역에 특화된 모델은 아니기 때문이다. 첫 점을 중심점이 아니라 무작위로 샘플링하면 SAM 과 기존 방법의 격차가 오히려 커지며, SAM 은 두 샘플링 방식에서 비슷한 성능을 유지한다.

7.2 제로샷 엣지 검출

방법

고전적인 저수준 비전 과제인 BSDS500 엣지 검출에 SAM 을 적용한다. 16×16 규칙 격자의 전경 점을 입력하여 점당 세 개, 총 768 개의 마스크를 예측하고 NMS 로 중복을 제거한다. 이진화하지 않은 마스크 확률 맵에 Sobel 필터를 적용하고 엣지 NMS 등의 가벼운 후처리를 거쳐 엣지 맵을 만든다.



그림 10. BSDS500 에서의 제로샷 엣지 예측. SAM 은 엣지 맵을 예측하도록 학습되지 않았고 BSDS 이미지나 주석을 학습 중 사용하지 않았다.

method	year	ODS	OIS	AP	R50
HED [108]	2015	.788	.808	.840	.923
EDETR [79]	2022	.840	.858	.896	.930
<i>zero-shot transfer methods:</i>					
Sobel filter	1968	.539	-	-	-
Canny [13]	1986	.600	.640	.580	-
Felz-Hutt [35]	2004	.610	.640	.560	-
SAM	2023	.768	.786	.794	.928

표 3. BSDS500 제로샷 엣지 검출 결과. SAM 은 전용 최신 지도학습 모델보다는 낮지만, 오래된 제로샷 기법보다 크게 앞서고 HED 와 비교 가능한 수준의 일부 지표를 보인다.

결과

정성적으로 SAM 은 엣지 검출을 학습하지 않았음에도 합리적인 엣지 맵을 생성한다. 정답보다 더 많은 엣지를 예측하며, BSDS500 주석에 포함되지 않았지만 시각적으로 타당한 엣지도 포함한다. 이 성향은 50% 정밀도에서 재현율(R50)이 높지만 정밀도가 낮아지는 결과로 나타난다. BSDS500 의 주석 편향, 즉 어떤 엣지를 억제해야 하는지까지 학습한 전용 최신 방법보다는 뒤지지만, BSDS500 으로 학습된 초기 딥러닝 방법 HED 와 비교할 만하고 기존 제로샷 전이 방법보다 크게 낫다.

7.3 제로샷 객체 제안 생성

SAM 을 중간 수준 과제인 객체 제안(object proposal) 생성에 적용한다. 자동 마스크 생성 파이프라인을 약간 수정하여 생성된 마스크를 객체 제안으로 사용하고, 범주 수가 많은 LVIS v1 에서 표준 평균 재현율(AR)을 평가한다. 강한 비교 기준으로 ViTDet-H + cascade Mask R-CNN 검출기를 사용한다.

method	all	mask AR@1000					
		small	med.	large	freq.	com.	rare
ViTDet-H [62]	63.0	51.7	80.8	87.0	63.1	63.3	58.3
<i>zero-shot transfer methods:</i>							
SAM – single out.	54.9	42.8	76.7	74.4	54.7	59.8	62.0
SAM	59.3	45.5	81.6	86.9	59.1	63.9	65.8

표 4. LVIS v1 객체 제안 생성의 mask AR@1000. SAM 은 제로샷으로 적용되며, 중간·대형 객체와 희귀·보통 빈도 객체에서는 ViTDet-H 보다 높은 결과를 보인다.

전체 평균에서는 LVIS 로 직접 학습된 ViTDet-H 가 가장 좋지만, SAM 은 여러 지표에서 매우 강하다. 중간·대형 객체, 희귀·보통 객체에서는 ViTDet-H 보다 높다. SAM 이 뒤지는 영역은 작은 객체와 자주 등장하는 객체이며, 이 영역에서는 LVIS 로 학습된 ViTDet-H 가 데이터셋 고유의 주석 편향을 학습할 수 있다는 점이 작용한다. 모호성을 제거한 단일 출력 SAM 은 모든 AR 지표에서 완전한 SAM 보다 상당히 낫다.

7.4 제로샷 인스턴스 분할

더 고수준의 비전 과제로, SAM 을 인스턴스 분할 시스템의 분할 모듈로 사용한다. 구현은 단순하다. ViTDet 객체 검출기의 출력 박스를 SAM 에 프롬프트로 제공한다. 이는 SAM 이 더 큰 시스템의 구성요소로 조합될 수 있음을 보여준다.

method	COCO [66]				LVIS v1 [44]			
	AP	AP ^S	AP ^M	AP ^L	AP	AP ^S	AP ^M	AP ^L
ViTDet-H [62]	51.0	32.0	54.3	68.9	46.6	35.0	58.0	66.3
<i>zero-shot transfer methods (segmentation module only):</i>								
SAM	46.5	30.8	51.0	61.7	44.7	32.5	57.6	65.5



표 5. COCO 및 LVIS v1 인스턴스 분할 결과. 완전 지도학습 ViTDet-H 가 AP 에서는 앞서지만, 고품질 LVIS 마스크에서는 격차가 작다.

with ViTDet boxes to do zero-shot segmentation. The fully-supervised ViTDet outperforms SAM, but the gap shrinks on the higher-quality LVIS masks. Interestingly, SAM outperforms ViTDet according to human ratings (see Fig. 11).




그림 11. LVIS 정답 박스에 적용한 ViTDet와 SAM의 마스크 품질 사람 평가 분포. AP는 낮지만 SAM의 사람이 평가한 마스크 품질은 ViTDet보다 높다.

COCO와 LVIS의 mask AP에서는 SAM이 ViTDet보다 낮지만 격차는 크지 않다. 시각적으로는 SAM의 경계가 더 선명하고 마스크 품질이 더 좋아 보이는 경우가 많았다. 이를 확인하기 위한 사람 평가에서 SAM은 ViTDet보다 일관되게 높은 점수를 받았다.

저자들은 COCO에서는 정답 마스크 품질 자체가 상대적으로 낮고 ViTDet가 그 고유한 주석 편향을 학습할 수 있기 때문에 AP 격차가 더 크게 나타날 수 있다고 해석한다. LVIS는 정답 품질이 높지만 마스크에 구멍이 없고 단순 다각형으로 구성되는 등 데이터셋 고유의 특성이 있다. SAM은 제로샷 방식이어서 이러한 편향을 학습할 기회가 없다.

7.5 제로샷 텍스트-투-마스크

방법

자유 형식 텍스트로 객체를 분할하는 더 고수준의 과제를 개념증명으로 탐색한다. 이전 실험에서는 동일한 SAM을 사용했지만 이 실험에서는 새로운 텍스트 주석을 추가하지 않고도 텍스트를 인식할 수 있도록 학습 절차를 수정한다. 수동으로 수집한 충분히 큰 마스크마다 CLIP 이미지 임베딩을 추출하고, 학습의 첫 상호작용 프롬프트로 이 임베딩을 사용한다. CLIP의 이미지 임베딩과 텍스트 임베딩은 같은 공간에 정렬되므로 학습 때는 이미지 임베딩을 사용하고, 추론 때는 CLIP 텍스트 인코더의 텍스트 임베딩을 SAM 프롬프트로 사용할 수 있다.




그림 12. 제로샷 텍스트-투-마스킹. "a wheel" 같은 단순한 표현뿐 아니라 "beaver tooth grille" 같은 더 구체적인 표현으로도 객체를 분할한다. 텍스트만으로 잘못된 객체를 고른 경우 점 프롬프트를 추가하면 수정되는 예를 보여준다.

결과

SAM은 "a wheel"과 같은 간단한 텍스트와 "beaver tooth grille" 같은 미묘한 문구에서도 객체를 분할할 수 있다. 텍스트 프롬프트만으로 올바른 객체를 선택하지 못한 경우에는 하나의 점 프롬프트를 추가하면 예측이 수정되는 경우가 많다. 저자들은 이 결과를 초기 개념증명으로 평가하며 완전히 견고한 텍스트 분할 시스템이라고 주장하지 않는다.

7.6 절제 연구

23개 데이터셋의 단일 중심점 프로토콜에서 데이터 엔진 단계, 데이터 규모, 이미지 인코더 규모를 절제한다. 단일 점은 모호할 수 있고 정답에는 가능한 여러 마스크 중 하나만 존재하기 때문에, 기본 상위 마스크뿐 아니라 세 출력 중 정답과 가장 잘 맞는 oracle 결과도 함께 보고한다.




그림 13. 데이터 엔진 단계, 학습 데이터 규모, 이미지 인코더 규모에 대한 절제 실험. 각 데이터 엔진 단계가 성능을 향상시키며, 자동 데이터만 사용해도 전체 단계 데이터와 거의 같은 결과를 얻는다. 전체 SA-1B의 약 10%인 100만 장으로도 상당히 근접한 성능을 내며, ViT-H는 ViT-B보다 크게 향상되지만 ViT-L 대비 향상은 작아진다.

데이터 엔진 단계별 누적 데이터를 사용하면 각 단계가 mIoU를 높인다. 세 단계 전체를 함께 학습할 때 자동 마스크가 수동/반자동 마스크를 압도적으로 많이 차지하므로 수동·반자동 마스크를 10배 오버샘플링하는 것이 가장 좋았지만 학습 설정이 복잡해진다. 자동 마스크만 사용한 설정은 전체 데이터를 사용한 경우보다 약 0.5 mIoU만 낮아, 기본 학습에서는 자동 마스크만 사용한다.

데이터 규모 절제에서 전체 1,100 만 장을 100 만 장과 10 만 장으로 균일 샘플링한다. 10 만 장에서는 모든 설정에서 mIoU 가 크게 하락하지만, 전체의 약 10%인 100 만 장에서는 전체 데이터와 비슷한 결과를 얻는다. 이때도 약 1 억 개의 마스크가 포함되므로 많은 실제 사용 사례에서 현실적인 학습 규모가 될 수 있다.

이미지 인코더를 ViT-B, ViT-L, ViT-H 로 확장하면 ViT-H 가 ViT-B 보다 확실히 높지만 ViT-L 에서 ViT-H 로의 향상은 상대적으로 작다. 현재 규모에서 인코더를 더 크게 키우는 것의 이득은 포화되는 것으로 보인다.

8. 논의

한계

SAM 은 전반적으로 잘 작동하지만 완벽하지 않다. 미세한 구조를 놓칠 수 있고, 때때로 작고 분리된 가짜 구성요소를 만들어내며, 확대하여 세밀하게 처리하는 계산량이 큰 전용 방법만큼 경계가 날카롭지 않을 수 있다. 많은 점을 제공하는 고정밀 인터랙티브 분할에서는 전용 인터랙티브 모델이 SAM 보다 나을 것으로 예상된다. SAM 은 매우 높은 IoU 에 특화하기보다 범용성과 폭넓은 사용성을 목표로 설계되었다.

프롬프트 처리 자체는 실시간이지만 무거운 이미지 인코더까지 포함한 전체 계산은 실시간이 아닐 수 있다. 텍스트-투-마스크는 탐색적 실험으로 완전히 견고하지 않다. SAM 이 많은 과제를 수행할 수 있더라도 시맨틱 분할이나 파노믹 분할을 단순한 프롬프트 설계만으로 구현하는 방법은 명확하지 않다. 또한 특정 도메인에서는 해당 도메인에 특화된 도구가 SAM 보다 나을 수 있다.

파운데이션 모델

사전학습 모델을 다운스트림 과제에 적응시키는 방식은 오래전부터 사용되어 왔고, 최근에는 규모 확대와 함께 '파운데이션 모델'이라는 개념으로 강조된다. 즉 넓은 데이터로 대규모 학습되고 다양한 다운스트림 과제에 적응 가능한 모델이다 [8]. SAM 은 이 정의와 잘 맞지만, 이미지 분할 자체가 컴퓨터 비전의 중요한 부분집합이므로 그 범위에는 본질적인 한계가 있다.

또한 파운데이션 모델에서 자기지도학습의 역할을 강조한 관점과 비교할 필요가 있다. SAM 의 이미지 인코더는 MAE 자기지도 사전학습으로 초기화되지만, 모델의 대부분의 능력은 대규모 지도학습에서 나온다. 저자들은 데이터 엔진을 통해 주석을 대규모로 확장할 수 있는 경우 지도학습도 매우 효과적인 해법이 될 수 있다고 본다.

조합 가능성

사전학습 모델은 학습 당시 상상하지 못한 새로운 능력의 구성요소가 될 수 있다. CLIP 이 DALL·E 같은 더 큰 시스템에 들어가는 것이 대표적인 예다. SAM 은 다양한 분할 프롬프트에서 유효한 마스크를 예측하도록 설계함으로써 다른 구성요소와 연결하기 쉬운 신뢰성 있는 인터페이스가 되는 것을 목표로 한다. 예를 들어 다른 모델이 선택한 관심 객체를 SAM 이 분할해 단일 RGB-D 이미지의 3D 재구성에 사용할 수 있고, 웨어러블 장치가 검출한 시선 위치를 점 프롬프트로 넣어 새로운 응용을 만들 수도 있다. SAM 이 1 인칭 이미지 같은 새로운 도메인에 일반화하기 때문에 이런 시스템은 추가 학습 없이도 작동할 가능성이 있다.

결론

Segment Anything 프로젝트는 이미지 분할을 파운데이션 모델의 시대에 맞게 확장하려는 시도다. 핵심 기여는 새로운 과제인 프롬프트 가능한 분할, 모델 SAM, 데이터셋 SA-1B 의 세 가지다. SAM 이 실제로 파운데이션 모델의

지위를 얻는지는 커뮤니티에서 어떻게 사용되는지에 달려 있지만, 10 억 개 이상의 마스크 공개와 프롬프트 가능한 분할이라는 관점이 향후 연구에 중요한 기반을 제공할 것으로 기대한다.

감사의 글

저자들은 연구 토론, 모델 확장, 데이터 주식 플랫폼, 웹 버전 최적화, 데모와 데이터셋 뷰어 제작에 도움을 준 여러 동료에게 감사를 표한다.

부록 - 구현 세부사항 번역

원문 부록은 A) 모델 및 과제 세부사항, B) 자동 마스크 생성, C) RAI 추가 분석, D) 실험 구현, E) 사람 평가 설계, F) 데이터셋·주석·모델 카드, G) 주석 지침으로 구성된다.

A. Segment Anything 모델과 과제 세부사항

이미지 인코더

원칙적으로 이미지 인코더는 $C \times H \times W$ 형태의 이미지 임베딩을 출력하는 어떤 네트워크도 사용할 수 있다. 저자들은 확장성과 강력한 사전학습의 이점을 위해 MAE로 사전학습된 ViT를 사용한다. 구체적으로 ViT-H/16에 14×14 윈도우 어텐션과 동일 간격의 네 개 전역 어텐션 블록을 적용한다 [62]. 출력은 입력 이미지보다 16배 축소된 임베딩이다. 프롬프트마다가 아니라 이미지마다 한 번만 계산하므로 이미지 인코더에는 비교적 많은 FLOPs를 사용할 수 있다.

입력은 1024×1024 로 리사이즈하고 짧은 변을 패딩한다. 따라서 이미지 임베딩의 공간 크기는 64×64 다. 채널 차원은 1×1 합성곱으로 256으로 줄이고, 이어 256 채널의 3×3 합성곱을 적용한다. 각 합성곱 뒤에는 LayerNorm을 둔다.

프롬프트 인코더

희소 프롬프트는 256차원 벡터 임베딩으로 매핑한다. 점은 점 위치의 위치 인코딩과 전경/배경 여부를 나타내는 두 학습 임베딩 중 하나를 더해 표현한다. 박스는 좌상단·우하단 두 모서리의 위치 인코딩에 각 모서리 유형을 나타내는 학습 임베딩을 더한 쌍으로 표현한다. 자유 형식 텍스트는 CLIP 텍스트 인코더를 사용한다.

밀집 프롬프트인 마스크는 입력 이미지보다 4배 낮은 해상도로 입력한 뒤, 2×2 stride-2 합성곱 두 개를 이용해 추가로 4배 축소하며 출력 채널을 4와 16으로 만든다. 마지막 1×1 합성곱으로 채널을 256으로 맞춘다. 각 층 사이에는 GELU와 LayerNorm을 사용한다. 이렇게 만든 마스크 임베딩을 이미지 임베딩에 원소별로 더한다. 마스크 프롬프트가 없을 때는 'no mask'를 나타내는 학습 임베딩을 이미지 임베딩 각 위치에 더한다.




그림 14. 경량 마스크 디코더 세부 구조. 두 층의 디코더가 교차어텐션으로 이미지 임베딩과 프롬프트 토큰을 모두 업데이트한다. 이어 이미지 임베딩을 업샘플링하고, 업데이트된 출력 토큰으로 마스크를 동적으로 예측한다.

경량 마스크 디코더

프롬프트 임베딩 집합에 학습된 출력 토큰을 추가하고, 이를 이미지 임베딩과 함께 수정된 Transformer 디코더에 넣는다. 각 디코더 층은 네 단계를 수행한다. (1) 토큰 자기어텐션, (2) 토큰을 query로 이미지 임베딩에 교차어텐

션, (3) 점별 MLP 로 각 토큰 업데이트, (4) 이미지 임베딩을 query 로 토큰에 교차어텐션한다. 마지막 단계는 프롬프트 정보를 이미지 임베딩에 반영한다. SAM 은 두 개 디코더 층을 사용한다.

위치 정보를 잃지 않도록 이미지 임베딩이 어텐션 층에 들어갈 때마다 위치 인코딩을 더한다. 또한 원래 프롬프트 토큰 전체(위치 인코딩 포함)를 업데이트된 토큰의 query 와 key 에 다시 더해 프롬프트의 위치와 유형에 강하게 의존하도록 한다.

디코더 뒤에는 이미지 임베딩을 두 개의 transposed convolution 으로 4 배 업샘플링한다. 그 다음 출력 토큰을 3 층 MLP 에 통과시켜 업샘플된 이미지 임베딩 채널과 같은 차원의 벡터를 만든다. 마지막으로 공간 위치별 내적을 이용해 마스크를 예측한다. Transformer 임베딩 차원은 256, 토큰 MLP 내부 차원은 2048 이며, 64×64 이미지 임베딩이 들어가는 교차어텐션에서는 계산량을 줄이기 위해 query/key/value 채널을 128 로 줄인다. 모든 어텐션은 8 개 head 를 사용한다.

모호성 인식

하나의 프롬프트가 여러 유효한 마스크를 의미할 수 있으므로 기본적으로 세 개의 마스크를 동시에 예측한다. 학습에서는 정답과 세 예측 각각의 손실을 계산한 뒤 가장 작은 손실만 역전파한다. 예측 마스크를 순위화하기 위해 별도 출력 토큰으로 각 마스크와 객체 사이의 IoU 를 추정하는 작은 헤드를 추가한다. 여러 프롬프트가 주어지면 모호성이 크게 줄어들기 때문에 이 경우에는 별도의 네 번째 출력 토큰을 사용해 하나의 마스크만 반환한다.

손실

마스크 손실은 focal loss 와 dice loss 를 20:1 비율로 결합한다. IoU 예측 헤드는 예측 IoU 와 실제 예측 마스크의 정답 대비 IoU 사이의 평균제곱오차로 학습하며, 마스크 손실에 가중치 1.0 으로 더한다.

학습 알고리즘

인터랙티브 분할을 모의한다. 첫 프롬프트는 동일 확률로 전경 점 또는 바운딩 박스를 고른다. 점은 정답 마스크 내부에서 균일 샘플링하고, 박스는 정답 바운딩 박스에 변 길이의 10% 표준편차에 해당하는 좌표 노이즈를 최대 20 픽셀까지 추가한다. 첫 예측 이후에는 이전 예측과 정답 사이의 오류 영역에서 새 점을 샘플링한다. false negative 영역에서는 전경 점, false positive 영역에서는 배경 점이 된다. 이전 반복의 이전 마스크 대신 임계값 처리 전 mask logits 를 다음 프롬프트로 함께 제공한다.

반복 점을 8 개 이상 늘리면 이득이 줄어든다. 여기에 새 점을 추가하지 않고 모델이 자신의 마스크를 정제하게 하는 두 반복을 추가한다. 하나는 8 번의 반복 중 무작위 위치에, 다른 하나는 마지막에 둔다. 결과적으로 첫 입력 1 회 + 반복 샘플링 점 8 회 + 새 외부 정보가 없는 정제 2 회 = 총 11 회의 상호작용이 된다. 경량 마스크 디코더는 이미지 인코더 계산의 1% 미만이라 반복 비용이 작다.

학습 레시피

AdamW($\beta_1=0.9$, $\beta_2=0.999$)를 사용하며, 250 iteration 의 선형 learning-rate warmup 후 단계별 감소를 적용한다. 초기 learning rate 는 8×10^{-4} , 총 90k iteration(약 SA-1B 2 epoch)을 학습한다. 60k 와 86,666 iteration 에서 learning rate 를 각각 10 배 낮춘다. 배치 크기는 256 이미지, weight decay 는 0.1, drop path 는 0.4, layer-wise learning-rate decay 는 0.8 이다. 기본 학습에는 데이터 증강을 사용하지 않는다. MAE 로 사전학습한 ViT-H 에서 초기화하며, 1024×1024 입력과 큰 인코더 때문에 256 개의 GPU 에 분산한다. GPU 당 최대 64 개의 마스크를 무작위로 샘플링한다.

B. 자동 마스크 생성 세부사항

크롭

전체 이미지에서는 32×32 점 격자를 사용하고, 추가로 2×2 및 4×4 의 부분 중첩 확대 크롭 20 개를 만든다. 확대 크롭에는 각각 16×16 , 8×8 점 격자를 사용한다. 크롭은 원래 고해상도 이미지를 이용하며, 크롭 내부 경계에 닿는 마스크는 제거한다. 중복 제거를 위해 박스 기반 greedy NMS를 먼저 각 크롭 내부에서, 다음으로 크롭 간에 적용한다. 크롭 내부에서는 예측 IoU로 순위를 정하고, 크롭 간에는 더 많이 확대된 크롭에서 나온 마스크를 우선한다. NMS 임계값은 0.7이다.

필터링

세 가지 필터로 마스크 품질을 높인다. 첫째, 예측 IoU 점수가 88 이상인 신뢰도 높은 마스크만 남긴다. 둘째, 같은 soft mask를 서로 다른 임계값(-1, +1 logits)으로 이진화했을 때 두 결과의 IoU가 95 이상인 안정적인 마스크만 남긴다. 셋째, 이미지 전체의 95% 이상을 덮는 마스크는 대체로 유용하지 않아 제거한다. 임계값들은 전문 주석자의 품질 평가를 기준으로 마스크 수와 품질을 함께 확보하도록 선택했다.

후처리

자동 마스크의 약 4%에서는 작고 불필요한 연결요소가 나타났고, 또 다른 약 4%에서는 작은 가짜 구멍이 나타났다. 100 픽셀 미만의 연결요소는 제거하고, 100 픽셀 미만의 구멍은 채운다.

자동 생성용 모델

SA-1B 완전 자동 생성을 위해 기본 SAM보다 추론 속도를 조금 희생하고 마스크 생성 품질을 높인 특수 버전을 학습했다. 수동·반자동 데이터만으로 학습하고, 90k 대신 177,656 iteration을 학습했으며 large-scale jitter 증강을 사용한다. 모의 인터랙티브 학습에서는 점과 마스크만 사용하고 박스는 사용하지 않는다. 학습 시 점 수를 기본 9개에서 4개로 줄였고, 마스크 디코더는 2층 대신 3층을 사용한다.

C. RAI 추가 세부사항

SA-1B 지리 정보 추정

SA-1B 이미지는 지오타그가 없지만 이미지 내용과 촬영 장소를 설명하는 캡션이 존재한다. ELMo 기반 개체명 인식 모델로 캡션의 위치 엔터티를 추출하고 국가·주/도·도시 후보에 매핑한 뒤 하나의 국가를 추정한다.

"Georgia"처럼 국가명과 지역명이 겹치는 모호성이 있고 편향 가능성도 있으므로 이 위치 정보는 데이터셋 전체 분포 분석에만 사용하고 공개하지 않는다. 캡션도 이미지 공급자와의 계약상 공개하지 않는다.

COCO/Open Images 지리 정보

두 데이터셋은 위치 정보를 제공하지 않으므로 Flickr API의 메타데이터를 활용한다. COCO 학습셋의 약 24%(19,562 장), 마스크가 있는 Open Images 학습셋의 약 18%(493,517 장)에 대해 위치를 얻었다. 이는 근사치이며 위치가 확인된 샘플이 전체 데이터 분포를 완전히 대표한다고 보장할 수 없다.

소득 수준 추정

이미지의 추정 국가를 세계은행 분류와 연결해 소득 수준을 추정하고, 상위 중간소득과 하위 중간소득을 하나의 '중간소득' 범주로 합친다.

사람 및 의복 분할 공정성 추가 분석

MIAP 와 Open Images 를 결합하여 사람 마스크 약 3.9 천 개를 구성하고, 지각된 성별 표현 및 연령대별 성능을 비교한다. 의복 분할에서는 MIAP 사람 박스 내부에 있는 Open Images 의 의복 범주 정답 마스크 약 6.5 천 개를 사용한다. 의복의 경우 1 점 프롬프트에서 주로 남성적으로 지각되는 사람의 의복이 더 높은 mIoU 를 보여 95% 신뢰구간이 겹치지 않는다. 3 점 프롬프트에서는 격차가 줄어든다. 저자들은 이 편향을 실제 사용 시 유의해야 할 한계로 명시한다.

	mIoU at			mIoU at	
	1 point	3 points		1 point	3 points
<i>perceived gender presentation</i>					
feminine	76.3 $\pm$ 1.1	90.7 $\pm$ 0.5	older	81.9 $\pm$ 3.8	92.8 $\pm$ 1.6
masculine	81.0 $\pm$ 1.2	92.3 $\pm$ 0.4	middle	78.2 $\pm$ 0.8	91.3 $\pm$ 0.3
			young	77.3 $\pm$ 2.7	91.5 $\pm$ 0.9

표 6. 지각된 성별 표현과 연령대에 따른 의복 분할 mIoU. 1 점 프롬프트에서 남성적으로 지각되는 집단의 성능이 더 높고 신뢰구간이 겹치지 않는다.

D. 실험 구현 세부사항

D.1 단일 점 유효 마스크 평가

23 개 데이터셋은 1 인칭 영상, 현미경, X-ray, 수중, 항공, 시뮬레이션, 주행, 회화 등 다양한 도메인을 포함한다. 15,000 개가 넘는 마스크가 있는 데이터셋은 효율을 위해 약 10,000 개 마스크가 되도록 이미지를 무작위 샘플링한다. 모든 데이터셋의 사람 얼굴은 블러 처리한다.

첫 점은 기본적으로 객체 경계에서 가장 먼 내부 점을 선택하고, 이후 점은 정답과 직전 예측 사이 오류 영역의 경계에서 가장 먼 점을 선택한다. 더 어려운 설정에서는 첫 점을 무작위로 고른다. $N=\{1,2,3,5,9\}$ 개 점 이후 예측과 정답의 IoU 를 측정하고, 데이터셋별 mIoU 를 낸 뒤 23 개 데이터셋 평균을 최종 지표로 사용한다. 많은 점을 사용해 목표 IoU 까지 도달하는 데 필요한 점 수를 측정하는 전통적 인터랙티브 분할 평가와 달리, SAM 은 한두 개의 프롬프트로 빠르게 동작하는 응용에 초점을 둔다.

비교 모델은 RITM, FocalClick, SimpleClick 이며 각 저자가 공개한 가장 큰 모델과 폭넓은 학습 데이터 버전을 사용한다. 단일 점에서는 RITM 이 가장 강하므로 기본 비교 기준으로 사용한다. SAM 의 oracle 성능은 세 출력 중 정답과 가장 잘 맞는 마스크를 고르는 방식으로 계산하여 단일 점 모호성의 영향을 분리한다.

dataset	abbreviation & link	image type	description	mask type	source split	# images sampled	# masks sampled
Plant Phenotyping Datasets Leaf Segmentation [74]	PPDLS	Plants	Leaf segmentation for images of tobacco and ara plants.	Instance	N/A	182	2347
BBBC038v1 from Broad Bioimage Benchmark Collection [12]	BBBC038v1	Microscopy	Biological images of cells in a variety of settings testing robustness in nuclei segmentation.	Instance	Train	227	10506
Dataset fOr bOuldeRs Segmentation [80]	DOORS	Boulders	Segmentation masks of single boulders positioned on the surface of a spherical mesh.	Instance	DS1	10000	10000
TimberSeg 1.0 [38]	TimberSeg	Logs	Segmentation masks of individual logs in piles of timber in various environments and conditions. Images are taken from an operator's point-of-view.	Instance	N/A	220	2487
Northumberland Dolphin Dataset 2020 [100]	NDD20	Underwater	Segmentation masks of two different dolphin species in images taken above and under water.	Instance	N/A	4402	6100
Large Vocabulary Instance Segmentation [44]	LVIS	Scenes	Additional annotations for the COCO [66] dataset to enable the study of long-tailed object detection and segmentation.	Instance	Validation (v0.5)	945	9642
STREETS [91]	STREETS	Traffic camera	Segmentation masks of cars in traffic camera footage.	Instance	N/A	819	9854
ZeroWaste-f [6]	ZeroWaste-f	Recycling	Segmentation masks in cluttered scenes of deformed recycling waste.	Instance	Train	2947	6155
iShape [111]	iShape	Irregular shapes	Segmentation masks of irregular shapes like antennas, logs, fences, and hangers.	Instance	Validation	754	9742
ADE20K [117]	ADE20K	Scenes	Object and part segmentation masks for images from SUN [107] and Places [116] datasets.	Instance	Validation	302	10128
Occluded Video Instance Segmentation [81]	OVIS	Occlusions	Instance segmentation masks in videos, focusing on objects that are occluded.	Instance	Train	2044	10011
Hypersim [86]	Hypersim	Simulation	Photorealistic synthetic dataset of indoor scenes with instance masks.	Instance	Evermotion archinteriors volumes 1-55 excluding 20,25,40,49	338	9445
Night and Day Instance Segmented Park [22, 23]	NDISPark	Parking lots	Images of parking lots from video footage taken at day and night during different weather conditions and camera angles for vehicle segmentation.	Instance	Train	111	2577
EPIC-KITCHENS VISOR [28, 27]	VISOR	Egocentric	Segmentation masks for hands and active objects in ego-centric video from the cooking dataset EPIC-KITCHENS [27].	Instance	Validation	1864	10141
Plittersdorf dataset [46]	Plittersdorf	Stereo images	Segmentation masks of wildlife in images taken with the SOCRATES stereo camera trap.	Instance	Train, validation, test	187	546
Egocentric Hand-Object Segmentation [113]	EgoHOS	Egocentric	Fine-grained egocentric hand-object segmentation dataset. Dataset contains mask annotations for existing datasets.	Instance	Train (including only Ego4D [43] and THU-READ [97, 96])	2940	9961
InstanceBuilding 2D [17]	IBD	Drones	High-resolution drone UAV images annotated with roof instance segmentation masks.	Instance	Train (2D annotations)	467	11953
WoodScape [112]	WoodScape	Fisheye driving	Fisheye driving dataset with segmentation masks. Images are taken from four surround-view cameras.	Instance	Set 1	107	10266
Cityscapes [25]	Cityscapes	Driving	Stereo video of street scenes with segmentation masks.	Panoptic	Validation	293	9973
PIDray [104]	PIDRay	X-ray	Segmentation masks of prohibited items in X-ray images of baggage.	Instance	Test (hard)	3733	8892
Diverse Realism in Art Movements [24]	DRAM	Paintings	Domain adaptation dataset for semantic segmentation of art paintings.	Semantic	Test	718	1179
TrashCan [52]	TrashCan	Underwater	Segmentation masks of trash in images taken by underwater ROVs. Images are sourced from the J-EDI [69] dataset.	Instance	Train (instance task)	5936	9540
Georgia Tech Egocentric Activity Datasets [34, 63]	GTEA	Egocentric	Videos are composed of four different subjects performing seven types of daily activities with segmentation masks of hands.	Instance	Train (segmenting hands task)	652	1208

표 7. 제로샷 점 프롬프트 평가에 사용한 23 개 분할 데이터셋. 도메인, 마스크 유형, 사용 split, 샘플 이미지·마스크 수를 정리한다.

D.2 제로샷 엣지 검출

BSDS500 의 표준 ODS/OIS/AP/R50 지표를 사용한다. SAM 의 마스크 확률 맵에 Sobel 필터를 적용해 엣지 강도를 만들고, 이미지별 엣지 정규화와 NMS 등 표준 후처리를 적용한다. 원문 그림 15 는 SAM 이 학습 중 BSDS500 의 이미지·주석을 보지 않았음에도 다양한 장면에서 합리적 엣지를 만드는 추가 예를 보여준다.




그림 15. BSDS500 제로샷 엣지 예측의 추가 시각화. SAM은 엣지 맵 예측을 학습하지 않았으며 BSDS 이미지와 주석도 학습에 사용하지 않았다.

D.3 제로샷 객체 제안

자동 마스크 생성 파이프라인을 이용해 LVIS에서 객체 제안을 만든다. 크기·빈도별 AR@1000을 평가하며, 범주별 분석에서는 해당 LVIS 범주에 해당하는 정답 집합만 사용한다. 단일 출력 SAM도 비교하여 모호성 인식의 효과를 확인한다.

D.4 제로샷 인스턴스 분할

ViTDet의 박스와 클래스 점수는 그대로 사용하고, 박스 안의 마스크만 SAM으로 대체한다. 원문 그림 16에서는 SAM이 ViTDet보다 경계를 더 잘 따르는 사례가 많음을 보여준다. 제로샷 모델인 SAM은 학습 데이터의 특이한 주석 규칙을 배울 수 없기 때문에, 예를 들어 구멍을 허용하지 않는 LVIS 마스크 규칙과 다른 '시각적으로 유효한' 모달 마스크를 출력할 수 있다.




그림 16. LVIS v1의 제로샷 인스턴스 분할 예. SAM은 ViTDet보다 질적으로 높은 마스크를 만드는 경우가 많다. 제로샷이므로 특정 데이터셋의 주석 편향을 학습하지 않은 결과가 드러나는 사례도 있다.

D.5 제로샷 텍스트-투-마스크

텍스트 인식 SAM은 수동/반자동 단계의 마스크 중 충분히 큰 마스크에서 CLIP 이미지 임베딩을 얻어 학습한다. 추론에서는 같은 CLIP 공간의 텍스트 임베딩을 프롬프트로 넣는다. 텍스트-이미지 정렬이 완벽하지 않으므로 텍스트만으로 객체 선택이 실패할 수 있고, 이때 점 프롬프트를 추가하면 보완할 수 있다.

D.6 SAM 잠재 공간 탐색

SAM의 마스크 출력 토큰 임베딩 사이 유사도를 이용하면 같은 이미지 또는 다른 이미지의 의미적으로 비슷한 마스크를 찾는 성질을 관찰할 수 있다. 이는 명시적 의미 범주로 학습하지 않았더라도 잠재 공간에 일정 수준의 의미 구조가 형성됨을 시사한다.

mining data biases; see top-right as an example where SAM is unimodal given that mask annotations in LVIS have no holes.



그림 17. SAM 잠재 공간의 마스크 임베딩 유사도 임계값 시각화. 자홍색 박스가 질의 마스크이며 낮은/높은 임계값에서 유사 마스크가 어떻게 좁혀지는지 보여준다.

E. 사람 평가 실험 설계

사람 평가의 목적은 자동 IoU 지표가 포착하지 못하는 '유효한 마스크'의 품질을 평가하는 것이다. 주석자는 각 예측을 1-10 점으로 평가하며, 1은 무의미한 마스크, 10은 픽셀 수준으로 거의 완벽한 마스크를 의미한다. 데이터셋과 모델 순서는 무작위화하여 특정 모델에 대한 선입견을 줄이고, 품질 수준을 설명하는 구체적인 가이드와 예시를 제공한다.

실험에서는 SAM과 비교 기준의 평균 평점 차이에 대해 통계 검정을 수행하고 99% 신뢰구간도 보고한다. 전체적으로 SAM은 RITM 또는 ViTDet보다 높은 평가를 받고, 모호성 인식이 없는 단일 출력 SAM보다도 높다. 데이터셋별 분포에서도 이 경향이 반복된다.




그림 18. 사람 평가에서 데이터셋별 마스크 품질 점수 분포. SAM, 비교 모델, SAM 단일 출력, 정답 마스크의 평점 분포를 비교한다.

dataset	SAM > baseline		SAM > SAM single out.	
	p-value	CI ₉₉ ($\Delta\mu$)	p-value	CI ₉₉ ($\Delta\mu$)
<i>point input (RITM [92] baseline):</i>				
LVIS v0.5 [44]	4e-69	(1.40, 1.84)	2e-11	(0.29, 0.64)
VISOR [28, 27]	7e-98	(1.81, 2.24)	7e-26	(0.58, 0.94)
DRAM [24]	1e-76	(1.54, 2.00)	2e-24	(0.62, 1.03)
IBD [17]	2e-57	(1.03, 1.39)	1e-15	(0.32, 0.62)
NDD20 [100]	2e-86	(1.88, 2.37)	5e-08	(0.19, 0.55)
OVIS [81]	2e-64	(1.38, 1.84)	3e-10	(0.27, 0.63)
iShape [111]	2e-88	(1.97, 2.47)	7e-23	(0.65, 1.10)
<i>box input (ViTDet-H [62] baseline):</i>				
LVIS v1 [44]	2e-05	(0.11, 0.42)	N/A	N/A

tests for two hypotheses: (1) that SAM gets higher scores than the baseline model (RITM or ViTDet) and (2) that SAM gets higher scores than single-output SAM. P-values are calculated via a paired t-test on the means of the model scores, which we supplement with a paired bootstrap test on 10k samples to find the 99% confidence interval for the difference of means. Table 8 shows p-values and confidence intervals for these tests. All statistical tests are strongly significant, and all confidence intervals exclude zero.

For instance segmentation, Fig. 11 of the main text

표 8. 사람 평가의 통계 검정 결과. SAM 이 비교 모델 및 단일 출력 SAM 보다 높은 점수를 받는다는 가설을 데이터셋별로 검정한다.

F. 데이터셋, 데이터 주석 및 모델 카드

원문은 SA-1B와 SAM의 구성·수집·배포·위험·사용 조건을 투명하게 기록하기 위해 데이터셋 카드, 데이터 주석 카드, 모델 카드를 제공한다. 아래에서는 원문의 질문-답변 구조와 의미를 유지하면서 한국어로 옮긴다.

F.1 SA-1B 데이터셋 카드

동기(Motivation)

1. 이 데이터셋은 어떤 목적으로 만들어졌는가? 네 가지 기여를 목표로 한다. (1) 1,100만 장의 이미지와 11억 개의 마스크로 당시까지 가장 큰 분할 데이터셋을 공개한다. (2) 공개 이미지의 얼굴과 차량 번호판을 흐리게 처리해

개인정보를 보호한다. (3) 연구 활용을 위한 사용 조건과 라이선스 하에 데이터를 제공한다. (4) 이전 데이터셋보다 지리적 다양성을 높여 더 공정하고 포용적인 비전 모델 연구에 기여한다.

2. 누가 만들었는가? Meta AI의 FAIR 팀이 만들었으며, 원본 이미지는 제 3자 사진 공급업체로부터 수집·라이선스하였다.

3. 누가 비용을 지원했는가? Meta AI가 데이터셋 구축 비용을 지원했다.

4. 기타 사항은 있는가? 별도의 추가 사항은 없다.

구성(Composition)

1. 데이터셋의 인스턴스는 무엇을 나타내는가? 모든 인스턴스는 사진이다. 장소, 물체, 장면 등 주제가 다양하다. 모든 사진은 서로 다른 이미지지만, 같은 피사체를 가까운 시점에 연속 촬영한 이미지 묶음이 일부 존재할 수 있다.

2. 총 인스턴스 수는 얼마인가? 1,100만 장의 이미지가 있다.

3. 더 큰 집합에서 샘플링된 데이터인가? 사진 공급업체로부터 라이선스한 이미지 전체로 구성된다. 대체로 사진이며 극소수의 예외가 있을 수 있다. 각 이미지에 생성된 자동 마스크를 포함하며, 약 2천 장의 이미지는 테스트 목적으로 무작위 보류하였다.

4. 각 인스턴스에는 어떤 데이터가 포함되는가? 각 인스턴스는 이미지이며, 공개 전 얼굴과 차량 번호판을 흐리게 처리하여 개인 식별 정보를 줄였다.

5. 라벨이나 목표값이 있는가? 각 이미지에는 분할 마스크가 있다. 마스크에 범주명이나 텍스트 라벨은 붙지 않는다. 이미지당 평균 약 100개, 전체 약 11억 개의 마스크가 있다.

6. 누락된 정보가 있는가? 각 이미지에는 사진 내용과 촬영 장소를 설명하는 짧은 자유형 캡션이 있으나, 사진 공급업체와의 계약상 공개할 수 없다. 논문에서는 지리적 분포 분석에만 이를 사용한다.

7. 인스턴스 사이 관계가 명시되어 있는가? 알려진 명시적 관계는 없다.

8. 오류·노이즈·중복이 있는가? 마스크는 분할 모델이 생성했기 때문에 오류나 불일치가 있을 수 있다. 동일 이미지는 없지만, 같은 피사체를 짧은 시간 간격으로 찍은 사진들이 존재할 수 있다.

9. 외부 자원에 의존하는가? 공개 데이터셋 자체는 독립적으로 사용할 수 있도록 구성되어 있다.

10. 기밀 정보가 포함되는가? 저자들은 기밀 정보가 포함되어 있지 않다고 설명한다.

11. 불쾌하거나 불안을 유발할 수 있는 콘텐츠가 있는가? 두 가지 안전 장치를 적용하였다. 첫째, 라이선스 공급업체의 이용 조건을 충족해야 하며 공급업체에 문제성 콘텐츠를 필터링하도록 요청했다. 둘째, 사용자가 문제 이미지를 발견하면 `segment-anything@meta.com`으로 신고해 삭제를 요청할 수 있다. 그럼에도 시위나 종교·정치적 의견과 관련된 집회 장면이 소수 남아 있을 수 있으며, 모든 유형을 완벽히 자동 제거하는 필터는 만들지 못했다고 밝힌다.

12. 연령·성별 등 하위집단을 식별하는가? 데이터셋 자체에는 사람의 하위집단을 식별하는 라벨이 없다.

13. 개인을 직접 또는 간접적으로 식별할 수 있는가? 공개 이미지에는 얼굴 블러 처리를 적용해 개인 식별 가능성을 낮춘다. 익명화 문제가 발견되면 이미지 ID와 함께 신고하도록 요청한다.

14. 민감한 정보가 포함될 수 있는가? 시위나 집회 장면이 종교적 신념, 정치적 의견 또는 노동조합 관련 맥락을 암시할 가능성은 있다. 다만 얼굴은 블러 처리되어 개인을 식별하지 못하도록 했다.

15. 기타 사항은 있는가? 별도의 추가 사항은 없다.

수집 과정(Collection Process)

1. 각 인스턴스와 연결된 데이터는 어떻게 얻었는가? 공개 마스크는 SAM 이 자동 추론하여 생성했다. 모델 보조 수동 주석으로 수집한 마스크는 공개하지 않는다. 자동 마스크 품질은 본문 § 5 에서 설명한 방식으로 검증했다.
2. 어떤 수집 장치·절차를 사용했는가? 이미지는 제 3 자 이미지 공급업체로부터 라이선스한 사진이며, 서로 다른 사진가가 다양한 카메라로 촬영한 것이다.
3. 샘플링 전략은 무엇인가? 라이선스한 이미지 대부분을 포함하고 약 2 천 장을 테스트용으로 무작위 보류하였다.
4. 누가 데이터에 라벨을 부여했는가? 공개되는 SA-1B 마스크는 완전 자동 단계에서 SAM 이 생성했다. 앞선 수동·반자동 주석 단계와 전문 주석자에 관한 정보는 § 4 와 F.2 에 기록되어 있으나 그 수동 주석 자체는 공개 대상이 아니다.
5. 데이터가 생성된 시간 범위는? 사진은 여러 연도에 걸쳐 촬영되었고 데이터 구축 시점 기준으로 2022 년까지의 이미지가 포함된다.
6. 윤리 검토 또는 개인정보 보호 검토가 있었는가? 저자들은 내부 개인정보 보호 검토를 수행했으며, 공개 전 얼굴과 차량 번호판을 블러 처리하였다.
7. 데이터는 어떻게 취득·허가되었는가? 원본 이미지는 제 3 자 사진 공급업체로부터 라이선스하였다.
- 8-9. 사진 속 당사자의 고지·동의 문제는 어떻게 다루었는가? 공급업체가 필요한 고지와 동의 권한을 갖추었다는 조건으로 이미지를 제공했으며, 공개 데이터에서는 알아볼 수 있는 얼굴과 번호판을 블러 처리한다. 라이선스 조건은 재식별 시도를 금지한다.
10. 데이터 삭제 요청 방법이 있는가? 사용자는 `segment-anything@meta.com` 으로 이미지 삭제를 요청할 수 있다.
11. 잠재적 피해를 줄이기 위해 어떤 조치를 했는가? 핵심 조치는 개인을 식별할 수 있는 얼굴·번호판 정보를 흐리게 처리하는 것이다.

전처리·정제·라벨링(Preprocessing / Cleaning / Labeling)

1. 어떤 전처리를 했는가? 공개용 이미지는 짧은 변이 1,500 픽셀이 되도록 축소하고, 얼굴과 번호판 등 식별 정보를 흐리게 처리한다.
2. 원본 데이터도 제공하는가? 블러 처리되지 않은 원본 사진은 안전 및 개인정보 보호 이유로 공개하지 않는다.
3. 어떤 자동화 도구를 사용했는가? 얼굴 검출에는 RetinaFace 를 사용했다. 번호판 블러 모델은 공개하지 않는다.

사용(Uses)

1. 이미 무엇에 사용했는가? SAM 을 학습하는 데 사용하였다.
2. 데이터셋 활용을 추적하는 중앙 저장소가 있는가? 중앙 추적 저장소는 없지만, 논문 인용을 통해 연구 활용을 파악할 수 있다.
3. 어떤 사용을 권장하는가? 대규모 이미지 분할과 파운데이션 모델 연구를 위한 데이터로 사용하도록 의도하였다. 커뮤니티가 새로운 주석을 추가해 확장하는 것도 가능하다.

4. 사용자가 주의해야 할 편향은 무엇인가? § 6 에서 지리·소득 분포와 공정성을 분석한다. 이전 데이터셋보다 다양하지만 집단 간 대표성이 동일한 것은 아니므로, 사용자는 학습된 편향 가능성을 고려해야 한다.

5. 금지되는 사용이 있는가? 구체적인 금지·제한 사항은 데이터셋 라이선스와 이용 조건에 따른다.

배포(Distribution)

1. 누구에게 제공되는가? 연구 커뮤니티에 제공한다.

2. 어디에서 받을 수 있는가? Segment Anything 데이터셋 배포 사이트를 통해 제공된다.

3. 최초 배포 시점은? 2023 년이다.

4-6. 라이선스와 규제·사용 제한은? 사용자는 다운로드·사용 전에 데이터셋 라이선스와 이용 조건에 동의해야 하며, 허용·제한되는 용도는 해당 조건을 따른다.

유지보수(Maintenance)

1. 누가 유지보수하는가? Meta AI 가 호스팅하고 유지보수한다.

2. 연락처는? `segment-anything@meta.com` 이다.

3. 정오표가 있는가? 당시 별도 정오표는 없다.

4. 데이터셋이 업데이트되는가? 주된 변경은 신고된 문제 이미지의 삭제다.

5. 보존 기간은? 별도의 데이터 보존 기한을 두지 않으며, 개인 식별 정보는 공개 전 제거한다. 문제가 있는 콘텐츠는 신고할 수 있다.

6. 이전 버전을 유지하는가? 잠재적으로 유해한 콘텐츠 제거가 업데이트의 목적이므로 이전 버전을 별도로 유지하지 않는다.

7. 외부 기여가 가능한가? 사용자는 추가 주석을 생성할 수 있으나, 그 주석의 호스팅과 배포는 각 사용자의 책임이다.

F.2 데이터 주석 카드

이 카드는 데이터 엔진의 첫 번째와 두 번째 단계에서 수행한 전문 주석 과정에 관한 정보를 정리한다.

과제 설계(Task Formulation)

1. 주관성이 개입되는가? 그렇다. 무엇을 하나의 객체로 묶을지는 주관적일 수 있다. 예를 들어 부츠 한 켤레를 하나의 마스크로 볼지 두 개의 마스크로 볼지 판단이 달라질 수 있다. 저자들은 완전한 정답 목록보다 다양한 마스크 확보를 더 중요하게 보았다.

2. 주석자 학습과 피드백은 어떻게 이루어졌는가? 주석자들은 전업으로 참여했고 이탈률이 낮았다. 시각적·영상 가이드, 연구 목표와 중간 결과 공유, 주간 회의를 통해 품질과 처리량을 개선했다.

3. 연구팀은 과제를 직접 시험했는가? 연구팀이 약 30 개의 주석 과제를 직접 수행하며 지침을 다듬었고, 주간 피드백과 질의응답을 통해 반복적으로 개선했다.

4. 주석자에게 위험한 콘텐츠가 있었는가? 명시적으로 확인된 특별한 위험은 없었으며, 문제성 이미지는 주석 이전 단계에서 가능한 한 필터링했다.

5. **핵심 주석 지침은 무엇이었는가?** 가능한 모든 객체를 분할하되, 전경·배경 클릭 또는 박스 프롬프트를 이용해 SAM의 마스크를 만든 뒤 필요하면 픽셀 정밀 브러시/지우개로 수정한다.

주석자 선정(Selecting Annotators)

1. 어떤 전문성을 가진 주석자를 사용했는가? 컴퓨터 비전 데이터 주석 경험이 있는 전문 주석자를 활용했다.
2. 새로운 관점을 의도적으로 포함했는가? 그렇지 않다고 보고한다.
3. 인구통계적 속성을 주석자 선정 기준으로 사용했는가? 성별, 연령 등 인구통계적 속성을 선정 기준으로 사용하지 않았다.
4. 주석자는 몇 명이며 어디에 있었는가? 약 130 명의 주석자가 참여했고 모두 케냐에 기반을 두었다. 저자들은 이러한 인구통계적 특성이 마스크 작업에 의미 있는 영향을 준다고 보지 않았다고 설명한다.
5. 주석자 구성과 데이터 사용에 관한 주의점은? SA-1B는 연구 용도로 제공되며 지리적 다양성을 확보하려 노력했다. 공정성·대표성에 관한 분석은 § 6에서 별도로 다룬다.

플랫폼과 작업 환경(Platform)

1. 어떤 주석 플랫폼을 사용했는가? 자체 구축한 전용 웹 기반 주석 플랫폼을 사용했다.
2. 품질 관리는 어떻게 했는가? 연구팀의 주간 수동 검토·피드백, 업체의 일일 QA, 스프레드시트와 채팅을 통한 오류·질문 공유를 결합했다. 이 과정이 주석 속도와 품질을 함께 개선했다.
3. 보상은 어떻게 결정했는가? 시간당 임금은 전문 주석 공급업체가 결정했으며, 해당 업체는 Certified B Corporation 이라고 논문에 기록되어 있다.

데이터셋 분석과 평가(Dataset Analysis / Evaluation)

1. 주석자 교육은 어떻게 했는가? 공급업체에서 하루의 교육을 받고 별도의 훈련 큐에서 연습했다. 일반적으로 약 1주일의 적응 기간을 거쳐 실제 작업에 참여했고, 이후에도 표본 검사와 주간 검토가 이어졌다.
2. 공통 오류는 어떻게 처리했는가? 반복되는 실수와 애매한 사례를 주간 회의에서 논의하고 지침과 피드백에 반영했다.
3. 수동 주석은 공개되는가? 수동 주석은 초기 SAM 학습에 사용되었지만 공개할 계획은 없다고 밝힌다.

공개와 유지보수(Release / Maintenance)

1. 주석이 변경될 수 있는가? 문제 이미지 삭제 같은 예외를 제외하면 기존 수동 주석을 변경할 계획은 없다.
2. 시간이 지나며 효용이 달라질 수 있는 조건이 있는가? 저자들은 특별히 알려진 조건이 없다고 보고한다.
3. 데이터는 어떤 조건으로 공개되는가? SA-1B는 연구용 라이선스 하에 제공되고 사용자는 조건에 동의해야 한다.
4. 수동 주석은 공개되는가? 공개할 계획이 없다.
5. 주석자가 자신의 주석을 철회하는 절차가 있는가? 별도의 철회 절차는 제공하지 않는다.

F.3 SAM 모델 카드

원문 표 9는 SAM의 모델 카드다. 주요 항목을 한국어로 옮기면 다음과 같다.

모델 개요

- **이름:** SAM(Segment Anything Model)
- **버전:** 1.0
- **연도:** 2023
- **개발 조직:** Meta AI / FAIR
- **모델 유형:** 다양한 분할 프롬프트에 응답하는 프롬프트 가능한 이미지 분할 모델
- **구조:** § 3 과 부록 A 에서 설명한 이미지 인코더, 프롬프트 인코더, 경량 마스크 디코더 구조
- **라이선스:** Apache 2.0 으로 모델 코드를 공개한다.

의도된 사용

점, 박스, 마스크 등 프롬프트로 이미지 내 객체·영역을 분할하는 것이 기본 용도다. 본문 실험에서처럼 점 기반 상호 작용, 엣지 검출, 모든 객체 분할/객체 제안, 검출기와 결합한 인스턴스 분할, 실험적 텍스트 프롬프트 등에 구성요소로 사용할 수 있다. 주 목적은 연구와 범용 분할 시스템 개발이다.

한계와 주의점

제로샷 환경에서는 하나의 프롬프트에 여러 개의 유효한 정답이 있을 수 있어 데이터셋의 단일 정답 마스크와 자동 지표가 불일치할 수 있다. SAM 은 미세 구조를 놓치거나 작은 분리 성분을 잘못 생성할 수 있으며, 매우 높은 경계 정밀도가 필요한 상황에서는 전용 모델이 더 나을 수 있다. 다운스트림 시스템에 결합될 때 새 편향이 발생할 수 있으므로 사용자가 별도의 공정성 평가를 수행해야 한다.

관련 요인과 평가 도메인

SAM 은 개별 사물(things)과 비정형 영역(stuff)을 모두 분할하도록 설계되었다. 제로샷 평가에는 시뮬레이션, 회화, 수중, 현미경, 운전 영상, 스테레오·어안 이미지 등 다양한 도메인이 포함된다.

평가 지표

단일·다중 점 프롬프트에는 mIoU 를 사용하고, 자동 지표의 모호성 문제를 보완하기 위해 사람 주석자에게 1-10 점 마스크 품질 평가를 받는다. 인스턴스 분할에는 AP, 객체 제안에는 AR@1000, BSDS500 엣지 검출에는 ODS/OIS/AP/R50 을 사용한다.

윤리·공정성 및 환경 비용

학습 데이터는 라이선스 사진을 사용하고 얼굴·차량 번호판을 블러 처리했다. 문제성 콘텐츠 필터링을 수행했으나 오탐·누락 가능성이 있고, 지리·소득 수준별 대표성 불균형도 완전히 해소되지는 않는다. 모델을 더 큰 시스템에 사용할 때의 공정성은 별도로 검증해야 한다.

모델 카드에는 학습 계산량도 기록되어 있다. 대표 학습은 A100 GPU 256 개를 약 68 시간 사용했으며, 저자들의 추산으로 약 6,963 kWh 의 전력을 사용하고 약 2.8 톤의 CO2 배출에 해당한다. 모델을 공개함으로써 여러 연구자가 동일 모델을 반복 재학습하는 비용을 줄이는 효과도 기대한다.

Model Overview	
Name	SAM or Segment Anything Model
Version	1.0
Date	2023
Organization	The FAIR team of Meta AI
Mode type	Promptable segmentation model
Architecture	See §3
Repository	https://github.com/facebookresearch/segment-anything
Citation	https://research.facebook.com/publications/segment-anything
License	Apache 2.0
Intended Use	
Primary intended uses	SAM is intended to be used for any prompt-based segmentation task. We explored its use in <i>segmenting objects from a point</i> (§7.1), <i>edge detection</i> (§7.2), <i>segmenting all objects</i> (§7.3), and <i>segmenting detected objects</i> (§7.4). We explored how SAM can integrate with other vision models to <i>segment objects from text</i> (§7.5).
Primary intended users	SAM was primarily developed for research. The license for SAM can be found at https://github.com/facebookresearch/segment-anything .
Out-of-scope use cases	See terms of use for SAM found at https://github.com/facebookresearch/segment-anything . See <i>Use Cases</i> under <i>Ethical Considerations</i> .
Caveats and recommendations	SAM has impressive zero-shot performance across a wide range of tasks. We note, however, that in the zero-shot setting there may be multiple valid ground truth masks for a given input. We recommend users take this into consideration when using SAM for zero-shot segmentation. SAM can miss fine structures and can hallucinate small disconnected components. See §8 for a discussion of limitations.
Relevant Factors	
Groups	SAM was designed to segment any object. This includes <i>stuff</i> and <i>things</i> .
Instrumentation and environment	We benchmarked SAM on a diverse set of datasets and found that SAM can handle a variety of visual data including <i>simulations</i> , <i>paintings</i> , <i>underwater images</i> , <i>microscopy images</i> , <i>driving data</i> , <i>stereo images</i> , <i>fish-eye images</i> . See §D.1 and Table 7 for information on the benchmarks used.
Metrics	
Model performance measures	We evaluated SAM on a variety of metrics based on the downstream task in our experiments. <i>mIoU</i>: We used the mean intersection-over-union after a given number of prompts to evaluate the segmentation quality of a mask when prompted with points. <i>Human evaluation</i>: We performed a human study (detailed in §E) to evaluate the real world performance of SAM. We compared the masks generated by SAM to a baseline state-of-the-art interactive segmentation model, RITM [92], using a perceptual quality scale from 1 to 10. <i>AP</i>: We used average precision to evaluate instance segmentation for a given box and edge detection. <i>AR@1000</i>: We used average recall to evaluate object proposal generation. <i>ODS</i>, <i>OIS</i>, <i>AP</i>, <i>R50</i>: We used the standard edge detection evaluation metrics from BSDS500 [72, 3].
Evaluation Data	
Data sources	See §D.1.
Training Data	
Data source	See Data Card in §F.1.
Ethical Considerations	
Data	We trained SAM on licensed images. The images were filtered for objectionable content by the provider, but we acknowledge the possibility of false negatives. We performed a geographic analysis of the SA-1B dataset in §6. While SA-1B is more geographically diverse than many of its predecessors, we acknowledge that some geographic regions and economic groups are underrepresented.
Cost and impact of compute	SAM was trained on 256 A100 GPUS for 68 hours. We acknowledge the environmental impact and cost of training large scale models. The environmental impact of training the released SAM model is approximately 6963 kWh resulting in an estimated 2.8 metric tons of carbon dioxide given the specific data center used, using the calculation described in [77] and the ML CO ₂ Impact calculator [61]. This is equivalent to ~7k miles driven by the average gasoline-powered passenger vehicle in the US [101]. We released the SAM models to both reduce the need for retraining and lower the barrier to entry for large scale vision research.
Risks and harms	We evaluated SAM for fairness in §6. Downstream use cases of SAM will create their own potential for biases and fairness concerns. As such we recommend users run their own fairness evaluation when using SAM for their specific use case.
Use cases	We implore users to use their best judgement for downstream use of the model.

표 9. 원문의 SAM Model Card. 모델 정보, 의도된 사용, 관련 요인, 평가 지표, 학습 데이터, 윤리·공정성 및 환경 관련 정보를 정리한다.

G. 사람 평가 주석 지침

이 부록은 SAM 과 비교 모델이 만든 마스크 품질을 사람 주석자가 1-10 점으로 평가할 때 사용한 실제 지침이다. 원문의 구조와 핵심 문구를 한국어로 옮기면 다음과 같다.

G.1 평가 목표와 화면 구성

목표는 점 또는 박스 프롬프트가 주어졌을 때 모델이 생성한 마스크가 얼마나 좋은지 비교하는 것이다. 하나의 작업(job)에서는 한 이미지의 마스크 하나를 평가한다. 주석 화면에는 다섯 개의 썸네일 보기가 제공되며 마우스를 올리면 확대되고, 클릭하면 전체 화면으로 볼 수 있다.

다섯 보기는 대체로 (1) 원본 이미지, (2) 원본 위에 빨간색 마스크를 겹친 보기, (3) 마스크를 노란색·배경을 보라색으로 표현한 마스크 중심 보기, (4) 확대된 원본, (5) 확대된 마스크 오버레이로 구성된다. 각 이미지에는 모델에 입력된 프롬프트를 표시하기 위해 파란 점 또는 파란색/흰색 박스가 보인다. 화면 하단의 1-10 버튼으로 품질을 선택한다.

작업 하나에는 최대 약 30 초를 사용하도록 안내한다. 문맥을 파악하기 위해 원본 이미지를 보고, 마스크만 보는 화면에서 구멍이나 흠어진 픽셀을 확인하며, 확대 보기에서 객체 경계가 얼마나 정확한지 살펴본다.

G.2 판단 기준 세 가지

기준 1 - 마스크가 실제 객체에 대응하는가? 마스크는 이미지에서 의미 있게 구별되는 객체 또는 영역을 나타내야 한다. 유효한 대상에는 개별 물체, 물체의 논리적인 부분, 서로 관련된 객체의 모음, 잔디·하늘 같은 'stuff' 영역이 포함될 수 있다.

객체 의미 수준의 대표적 오류에는 다른 객체의 일부를 잘못 포함하는 경우, 대상 객체의 큰 부분을 빠뜨리는 경우, 서로 관련 없는 객체를 하나로 합치는 경우, 점 프롬프트가 가리킨 컬렉션 중 임의의 일부만 부자연스럽게 선택하는 경우 등이 있다.

기준 2 - 경계 품질이 좋은가? 객체 윤곽을 정확히 따라야 한다. 대표적 오류는 객체 내부의 불필요한 구멍, 객체와 연결되지 않은 작은 가짜 픽셀·영역, 경계를 크게 벗어나는 윤곽, 가림(occlusion)을 일관되지 않게 처리하는 경우다. 매우 작은 객체에서 이미지 자체가 픽셀화되어 있다면 마스크 경계의 픽셀화는 객체와 잘 맞는 한 오류로 보지 않는다.

기준 3 - 점 또는 박스 프롬프트와 일치하는가? 점 프롬프트에서는 파란 점이 마스크 안에 있어야 한다. 점의 위치가 객체 중앙이 아니더라도 상관없으며, 한 점이 여러 의미 수준을 가리킬 수 있다. 예를 들어 장갑 낀 손 위의 점은 장갑 자체 또는 사람 전체 모두에 대해 유효할 수 있다. 박스 프롬프트에서는 박스의 크기와 위치에 가장 자연스럽게 대응하는 객체를 선택해야 한다. 박스가 약간 타이트하게 그려졌다면 마스크가 박스 밖으로 조금 나가는 것은 허용된다.

G.3 1-10 점 품질 척도

- **1 점:** 어떤 객체를 분할한 것인지 식별할 수 없거나 사실상 마스크가 보이지 않는 수준.
- **2-4 점:** 객체는 어느 정도 알아볼 수 있지만 품질이 매우 낮다. 잘못 포함된 큰 영역, 큰 누락, 심하게 얼룩진 경계 등 심각한 오류가 있다.
- **5-6 점:** 객체는 분명히 식별되고 대부분의 경계가 맞지만, 눈에 띄는 주요 오류가 하나 이상 있다. 예를 들면 중요한 분리된 부분의 누락, 다른 객체의 상당한 부분 포함, 특정 구간의 매우 나쁜 경계 등이 있다.
- **7-9 점:** 객체가 명확히 식별되고 오류가 작고 드물다. 예를 들어 심하게 가려진 작은 분리 구성요소가 빠지는 정도의 사소한 결함이 있을 수 있다.
- **10 점:** 식별 가능한 오류가 없는, 사실상 픽셀 수준으로 완벽한 마스크.

평가에서 중요한 것은 데이터셋의 기존 정답 마스크와 완전히 같은지를 기계적으로 보는 것이 아니라, 주어진 프롬프트에 대해 그 마스크가 실제로 유효한 객체를 나타내고 시각적으로 얼마나 좋은지를 판단하는 것이다. 이는 하나의 점이 여러 유효한 객체를 의미할 수 있는 SAM의 모호성 인식 설계를 공정하게 평가하기 위한 것이다.

We have several models that, when provided with a click or a box as input, output a mask. We would like to compare the quality of these models by rating the quality of their masks on many examples. The interface will be different than for regular mask annotation.

- Each job reviews one mask on one image
- On the right, there will be five image thumbnails in two rows. Each thumbnail can be moved over to show the image at a larger size. Clicking on the thumbnail will make it full screen, and clicking again will return to the original screen.
- The images show the same mask in five different views. On the top row, (left) the image without the mask, (middle) the mask overlaid on the image, and (right) the mask alone. On the bottom row, (left) a zoomed-in view of the object without a mask, and (right) a zoomed-in view of the mask overlaid on the image. These views are provided to make it easy to see different types of mask errors.
- The mask will be red when overlaid on the image.
- When shown by itself, the mask is yellow, and the background is purple.
- Each image will include either a blue dot or a blue and white box. This is the input to the model, as if you had clicked at this location or drawn this box.
- On the left, there are buttons labeled 1-10. This is used to rate the quality of the shown mask.


Objective and Setup



Example interface page. There will be five images on the right and a question box on the left.



Mouse over an image to show the full image.




Click on an image to make it full screen. The arrows will cycle between images. Click again to return to previous view.



The first image on the top row shows the image without a mask. A blue point will be on the object of interest, or a blue and white box will surround it.



The second image on the top row shows the mask for the object in red.




The third image on the top row shows the mask only. The mask is in yellow and the background is purple.



The first image on the bottom row shows a zoomed-in view of the object without a mask.



The second image on the bottom row shows a zoomed-in view of the object with a mask. The mask is in red.



On the left are buttons to rate the mask quality, with selections 1-10.

What we would like you to do for each job

- Please aim to spend up to 30 seconds per job.
- Mouse-over or click each of the three images of the mask on the right to get a sense of the quality of the mask. The thumbnail is too small to judge a mask, do not judge a mask by the thumbnail alone. Each image can provide a different signal on possible mask errors.
- The zoomed-in image can give context for the mask, does this mask correspond to an actual object?
- The zoomed image can show if the mask boundaries make sense.
- The zoomed image can show if the mask boundaries make sense.
- Judge the quality of the mask on three criteria. Examples will follow.
- Does the mask correspond to an actual object?
- Does the mask have a good boundary?
- Does the mask correspond to the provided point or box?
- Rate the quality of the mask on a scale of 1-10 using the drop-down box on the left.
- Next are details and examples for judging mask quality according to the three criteria. These are just examples and other cases may come up, please use your best judgment when determining if something is a good mask.

Task

Does the mask correspond to an actual object?


- Valid objects can include:
 - Entire single-objects (such as a person, shirt, or tree)
 - Logical parts of objects (such as a chair leg, a car door, a tabletop)
 - Collection of objects (a stack of books, a crowd of people)
 - 'Stuff' (the ground, the sky)
- Example errors a mask may have. The severity of these errors may be minor or major:
 - Include a piece of another object (the mask of a person including the arm of a nearby person)
 - Miss part of an object (the mask covers only one part of a building obscured by a tree in the foreground)
 - Combine two unrelated things (a single mask covers both a mug and a pen on a desk)
 - Include an arbitrary part of a collection (a point input to point to an apple, but the mask covers three apples in a pile of many apples). If a box surrounds an arbitrary collection, it is not an error to provide a mask for these objects.
- If you are unsure, a good rule of thumb is: can you name the object in question? However, some things that are hard to name may still be good objects (an animal component of a machine, something at the edge of the image for which it is hard to determine what it is).

Judging Mask Quality (1 of 3)

Does the mask have a good boundary?

- Errors in the boundary can include:
 - Incorrect holes in the mask
 - Incorrect pixels included separated from the main part of the mask
 - Poor edge quality, where the mask does not exactly match the edge of the object.
 - Failure to consistently handle obscuring foreground objects (a mask that covers obscuring objects is fine, and a mask that doesn't cover obscuring objects is fine, but one that does some of both has an error)
 - Pixelation of a small mask is not an error, as long as the mask will match the edges of the object.

Judging Mask Quality (2 of 3)



Example error of 'Include an arbitrary part of a collection': In top top image, the point is on one orange rind, but the mask covers two orange rinds. This is a mask error: the mask covers an arbitrary number of objects in the collection, and should either cover one orange rind or all of them. In the bottom image, the box is around both vegetables. Since this is the best match to the box, this is not a mask error.

Does the mask correspond to the provided point or box?

- Four points:
 - The point needs to be on the mask.
 - The size or position of the object with respect to the point does not matter (a point on someone's gloved hand can correspond to the glove or to the entire person, both are valid masks).
- Four boxes:
 - The object needs to be the best object that is the size of the box (if a box is around someone's entire head but the mask is of their hair, this is an error: their hair is in the box but is not the correct object)
 - If the box clearly corresponds to a given object but is slightly smaller than it, it is okay if the mask goes slightly outside a box (if a box around a person misses their extended hand, the mask can still include their hand even if the mask goes outside the box).

Judging Mask Quality (3 of 3)



Example error for 'Incorrect holes in the mask': This mask has holes in the upper left and on the left sides (black arrows). These holes are much easier to see on the 'mask only' image.



Example error of 'Include a piece of another object': The elephant mask contains a piece of another nearby elephant.



Example error of 'Missing a part of an object': The mask is missing a disconnected part of the object: the back half of the zebra, and the right portion of the plate.



Example error for 'Incorrect pixels included separated from the main part of the mask': The 'mask only' view reveals a few stray incorrect pixels on the clock face.



Example error for 'Poor edge quality': The mask has poor edge quality, both along the edge of the umbrella, as well as along the thin pole.


그림 19. 사람 평가 주석자에게 제공한 원문 마스크 품질 평가 지침(1/2). 화면 구성, 프롬프트 표시, 평가 절차와 다양한 오류 예시를 보여준다.




Example for 'Combine two unrelated things': The point indicates the lizard, but the mask covers both the lizard and a bird. This is a mask error.




Example error for 'Failure to consistently handle obscuring foreground objects': The pole on the right (blue arrow) is excluded from the mask, while the pole on the left is included in the object (black arrow). The mask should either include or exclude both of these.



Example of 'Pixelation of a small mask': this mask has an imperfect boundary, since it extends beyond the object at the black arrow. However, the 'blocky' pattern of the mask is not an error, since, when zoomed in this much, the image is also blocky the same way.




Example error for consistency with the provided point: The mask does not agree with the blue point, so this is a mask error.



Example for consistency with the provided point: For this input point, but the logo (left) and the container (right) are valid objects, since the blue point lies on both of them. Neither mask has a mask error.



Example for consistency with a box: The box surrounds the bowl of oranges, but the mask is only of a single orange. This is a mask error.



Example for consistency with a box: The box's shape fits the zebra. Even though the mask extends slightly outside the box to include the zebra's left leg, this is not an error.

- Overall mask quality is subjective; each of the above errors may hurt mask quality only a little at a lot, depending on how large the error is. Please use your best judgment when choosing mask scores, and try to stay consistent from mask-to-mask. Here are some general guidelines for what different scores should correspond to:
- A score of 1: It is not possible to tell what object this mask corresponds to. This includes the case that there is no mask visible at all.
 - A low score (2-4): The object is nearly identifiable, but the mask quality is extremely poor to 2: large regions of the mask cover other objects; large regions of the object missing; extremely spotty mask boundaries that cut through the middle of the object).
 - A mid score (5-6): The object is identifiable and the boundary is mostly correct, but there are major errors (missing a significant disconnected part of the object, containing a significant part of another object; very poor boundary quality in one area of the object but not the entire object).
 - A high score (7-9): The object is identifiable and errors are small and rare (missing a small, barely observed disconnected component; having small regions where the mask boundary does not quite match the object boundary).
 - A score of 10: The mask is pixel-perfect; it has no identifiable errors at all.

Mask Scoring




Example of a mask with a score of 1: It is not clear what object this mask corresponds to.




Example of a mask with a low score (2-4): The main object is identifiable, but the mask includes a large, incorrect portion of another object.



Example of a mask with a low score (2-4): The main object is identifiable, but a large, random part of the object is missing.



Example of a mask with a low-to-medium score (4-5): The object is identifiable and the edges are all correct, but the mask incorrectly includes the hand of the person on the left.



Example of a mask with a medium score (5-6): The mask clearly corresponds to the plate, but the boundary with the waffle is quite poor.



Example of a mask with a medium score (5-6): the object is easy to identify, and most of the edges make sense. However, there is a significant disconnected part (their arm inside the frame) that is mostly missing, as well as splochy pixels in this region.



Example of a mask with a medium-to-high score (6-8): the mask has two small-ish regions of poor boundary, at the top of the mask and on the bottom right.




Example of a mask with a medium-to-high score (6-8): The wreath is a valid object that is the size of the box (the entire wreath + clock would also be a valid object). However, there are incorrect stray mask pixels on the clock.



Example of a mask with a high score (7-9): The boundary of the horse is almost entirely correct, except for the right side of its back leg. The mask consistently includes all of the equipment that horse is wearing, and has logical boundaries.



Example of a mask with a very high score (~9): There are only minor errors around the edge of the mask. The blocky 'pixelation' is not an error, since the image is also blocky at this scale.



Example of a mask with a very high score (9-10): the mask has only very minor errors in the edge on the bottom right.



Example of a mask with a very high score (9-10): There are only minor errors around the edge of the mask.

그림 20. 사람 평가 주석자에게 제공한 원문 마스크 품질 평가 지침(2/2). 1-10 점 품질 척도와 실제 예측 마스크의 점수 예시를 보여준다.

참고문헌

참고문헌의 저자명, 논문 제목, 학술대회·저널명, 연도는 인용 정확성을 위해 원문의 영어 서지정보를 그대로 사용하는 것을 권장한다. 본 번역본의 본문 인용 번호 [1]-[117]은 업로드된 원문의 참고문헌 번호와 동일하다.

원문 논문: Alexander Kirillov et al., "Segment Anything", arXiv:2304.02643v1, 5 Apr 2023.